DeepSeek-V3 技术报告

左元翻译

日期：February 6, 2025

摘　要

我们推出了 DeepSeek-V3，这是一个强大的混合专家（Mixture-of-Experts, MoE）语言模型，总参数量为 6710 亿，每个 token 激活的参数量为 370 亿。为了实现高效的推理和成本效益高的训练，DeepSeek-V3 采用了多头潜在注意力（Multi-head Latent Attention, MLA）和 DeepSeekMoE 架构，这些架构在 DeepSeek-V2 中得到了充分验证。此外，DeepSeek-V3 首创了一种无辅助损失的负载均衡策略，并设定了多 token 预测的训练目标，以实现更强的性能。我们在 14.8 万亿个多样且高质量的 token 上对 DeepSeek-V3 进行了预训练，随后通过监督微调（Supervised Fine-Tuning）和强化学习（Reinforcement Learning）阶段充分挖掘其潜力。综合评估表明，DeepSeek-V3 的表现优于其他开源模型，并与领先的闭源模型性能相当。尽管性能卓越，DeepSeek-V3 的完整训练仅需 278.8 万 H800 GPU 小时。此外，其训练过程非常稳定。在整个训练过程中，我们没有遇到任何不可恢复的损失突增或执行任何回滚操作。模型检查点可在https://github.com/deepseek-ai/DeepSeek-V3获取。

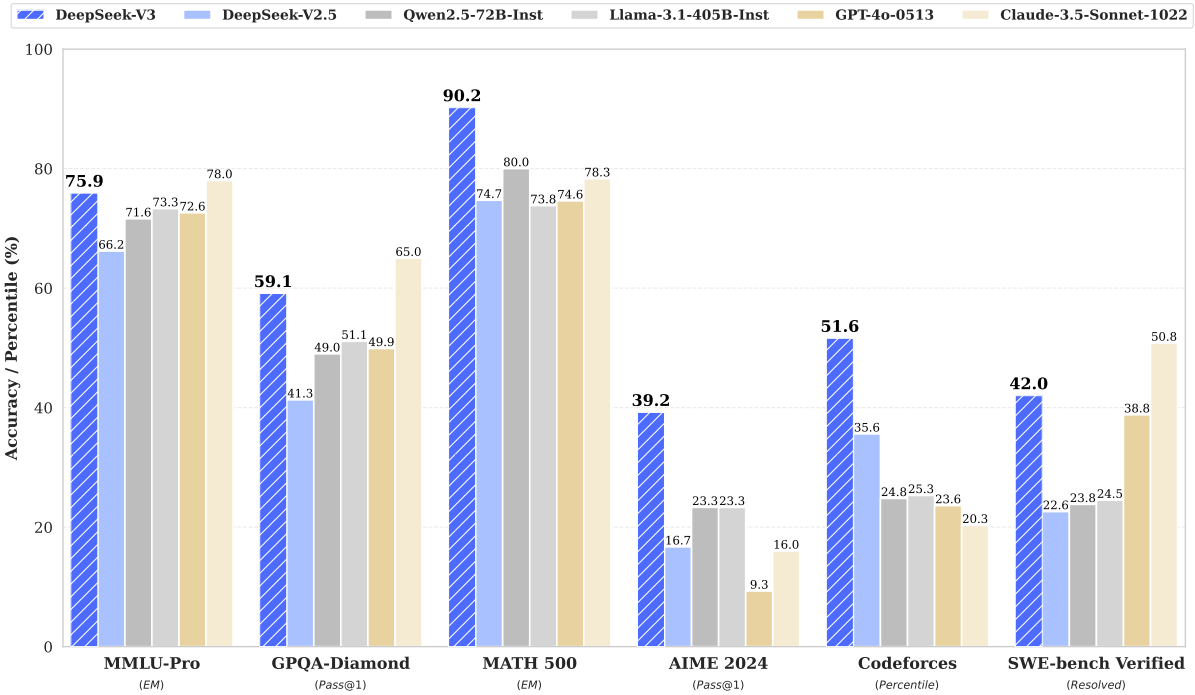

图 1: DeepSeek-V3 和竞品在性能基准测试中的比较。

目录

1 简介 **4**

2 架构 **6**

2.1 基本架构 6

2.1.1 多头潜在注意力 (Multi-Head Latent Attention) 6

2.1.2 DeepSeekMoE with Auxiliary-Loss-Free Load Balancing 8

2.2 多 Token 预测 (Multi-Token Prediction) 8

3 基础设施 **8**

3.1 计算集群 8

3.2 训练框架 8

3.2.1 DualPipe and Computation-Communication Overlap 8

3.2.2 Efficient Implementation of Cross-Node All-to-All Communication 8

3.2.3 Extremely Memory Saving with Minimal Overhead 8

3.3 FP8 精度训练 8

3.4 推理和部署 8

3.4.1 Prefilling 8

3.4.2 解码 8

3.4.3 Communication Hardware 8

3.4.4 Compute Hardware 8

4 预训练 **8**

4.1 训练数据的构成 8

4.2 超参数 9

4.3 长上下文扩展 9

4.4 评估 9

4.4.1 评估结果 9

4.5 讨论 9

4.5.1 Ablation Studies for Multi-Token Prediction 9

4.5.2 Ablation Studies for the Auxiliary-Loss-Free Balancing Strategy 9

4.5.3 Batch-Wise Load Balance VS. Sequence-Wise Load Balance 9

5 后训练 **9**

5.1 监督微调 (Supervised Fine-Tuning) 9

5.2 强化学习 9

5.2.1 奖励模型 9

5.2.2 组相对策略优化 (Group Relative Policy Optimization) 9

5.3 评估 9

5.3.1 评估设置 9

5.3.2 标准评估 9

5.3.3 Open-Ended Evaluation 9

5.3.4 DeepSeek-V3 as a Generative Reward Model 9

5.4 讨论 9

5.4.1 从 DeepSeek-R1 蒸馏 9
5.4.2 Self-Rewarding 9
5.4.3 Multi-Token Prediction Evaluation 9

6 结论，局限性和未来的方向 9

Training Costs	Pre-Training	Context Extension	Post-Training	Total
in H800 GPU Hours	2664K	119K	5K	2788K
in USD	$5.328M	$0.238M	$0.01M	$5.576M

表 1: DeepSeek-V3 的训练花费，假设 H800 每个 GPU 小时的租赁费用是 $2。

1 简介

近年来，大语言模型（Large Language Models, LLMs）正在经历快速的迭代和演进，逐步缩小与通用人工智能（Artificial General Intelligence, AGI）的差距。除了闭源模型外，开源模型，包括 DeepSeek 系列、LLaMA 系列、Qwen 系列和 Mistral 系列，也在取得显著进展，努力缩小与闭源模型的差距。为了进一步突破开源模型的能力边界，我们扩大了模型规模，并推出了 DeepSeek-V3，这是一个拥有 6710 亿参数的大型混合专家（Mixture-of-Experts, MoE）模型，其中每个 token 激活的参数量为 370 亿。

以前瞻性的视角，我们始终致力于实现强大的模型性能和经济的成本。因此，在架构方面，DeepSeek-V3 仍然采用多头潜在注意力（MLA）以实现高效推理，以及 DeepSeekMoE 以实现成本效益高的训练。这两种架构在 DeepSeek-V2 中得到了验证，证明了它们在保持强大模型性能的同时实现高效训练和推理的能力。除了基础架构外，我们还实施了两项额外策略以进一步增强模型能力。首先，DeepSeek-V3 首创了一种无辅助损失的负载均衡策略，旨在最小化因鼓励负载均衡而对模型性能产生的负面影响。其次，DeepSeek-V3 采用了多 token 预测的训练目标，我们观察到这可以提升评估基准上的整体性能。

为了实现高效的训练，我们支持 FP8 混合精度训练，并对训练框架进行了全面优化。低精度训练已成为高效训练的一种有前景的解决方案，其发展与硬件能力的进步密切相关。在这项工作中，我们引入了 FP8 混合精度训练框架，并首次在超大规模模型上验证了其有效性。通过支持 FP8 计算和存储，我们实现了训练加速和 GPU 内存使用量的减少。在训练框架方面，我们设计了 DualPipe 算法以实现高效的流水线并行，该算法减少了流水线气泡，并通过计算-通信重叠隐藏了训练过程中的大部分通信。这种重叠确保了随着模型的进一步扩展，只要我们保持恒定的计算与通信比率，我们仍然可以在节点间使用细粒度的专家，同时实现近乎零的全对全通信开销。此外，我们还开发了高效的跨节点全对全通信内核，以充分利用 InfiniBand（IB）和 NVLink 的带宽。此外，我们精心优化了内存占用，使得在不使用昂贵的张量并行的情况下训练 DeepSeek-V3 成为可能。结合这些努力，我们实现了高效的训练。

在预训练阶段，我们在 14.8 万亿个高质量且多样化的 token 上训练了 DeepSeek-V3。预训练过程非常稳定。在整个训练过程中，我们没有遇到任何不可恢复的损失突增，也没有进行任何回滚操作。接下来，我们对 DeepSeek-V3 进行了两阶段的上下文长度扩展。在第一阶段，最大上下文长度扩展到 32K，在第二阶段进一步扩展到 128K。随后，我们对 DeepSeek-V3 的基础模型进行了后训练，包括监督微调（Supervised Fine-Tuning, SFT）和强化学习（Reinforcement Learning, RL），以使其与人类偏好对齐并进一步释放其潜力。在后训练阶段，我们从 DeepSeek-R1 系列模型中蒸馏了推理能力，同时精心平衡了模型准确性和生成长度之间的关系。

我们在广泛的基准测试上对 DeepSeek-V3 进行了评估。尽管训练成本经济，综合评估表明，DeepSeek-V3-Base 已成为当前最强的开源基础模型，尤其是在代码和数学领域。其聊天版本也在标准基准和开放式基准测试中优于其他开源模型，并与领先的闭源模型（包括 GPT-4o 和 Claude-3.5-Sonnet）性能相当。

最后，我们再次强调 DeepSeek-V3 的经济训练成本，总结在表 1中，这是通过我们对算法、框架和硬件的优化协同设计实现的。在预训练阶段，每万亿 token 的训练仅需 18 万 H800 GPU 小时，即在我们拥有 2048 个 H800 GPU 的集群上仅需 3.7 天。因此，我们的预训练阶段在不到两个月内完成，并消耗了 266.4 万 GPU 小时。结合上下文长度扩展所需的 11.9 万 GPU 小时和后训练的 0.5 万 GPU 小时，DeepSeek-V3 的完整训练仅需 278.8 万 GPU 小时。假设 H800 GPU 的租赁价格为每小时 2 美元，我们的总训练成本仅为 557.6 万美元。需要注意的是，上述成本仅包括 DeepSeek-V3 的官方训练，不包括在架构、算法或数据

上的前期研究和消融实验相关成本。

我们主要的贡献包括：

架构：创新的负载均衡策略和训练目标

- 在 DeepSeek-V2 的高效架构基础上，我们首创了一种无辅助损失的负载均衡策略，最大限度地减少了因鼓励负载均衡而导致的性能下降。
- 我们研究了多 token 预测（Multi-Token Prediction, MTP）目标，并证明其对模型性能有益。它还可以用于推测解码（speculative decoding）以实现推理加速。

预训练：通往终极的训练效率

- 我们设计了一个 FP8 混合精度训练框架，并首次在超大规模模型上验证了 FP8 训练的可行性和有效性。
- 通过算法、框架和硬件的协同设计，我们克服了跨节点 MoE 训练中的通信瓶颈，实现了近乎完全的计算-通信重叠。这显著提高了我们的训练效率并降低了训练成本，使我们能够在不增加额外开销的情况下进一步扩大模型规模。
- 仅以 266.4 万 H800 GPU 小时的经济成本，我们完成了 DeepSeek-V3 在 14.8 万亿 token 上的预训练，生成了当前最强的开源基础模型。预训练后的后续训练阶段仅需 10 万 GPU 小时。

后训练：从 DeepSeek-R1 进行知识蒸馏

- 我们引入了一种创新方法，将长思维链（Chain-of-Thought, CoT）模型（特别是 DeepSeek R1 系列模型之一）的推理能力蒸馏到标准 LLM（尤其是 DeepSeek-V3）中。我们的管道巧妙地将 R1 的验证和反思模式融入 DeepSeek-V3，显著提升了其推理性能。同时，我们还控制了 DeepSeek-V3 的输出风格和长度。

核心评估结果总结

- **知识**: (1) 在教育类基准测试（如 MMLU、MMLU-Pro 和 GPQA）上，DeepSeek-V3 优于所有其他开源模型，在 MMLU 上得分为 88.5，在 MMLU-Pro 上得分为 75.9，在 GPQA 上得分为 59.1。其性能与领先的闭源模型（如 GPT-4o 和 Claude-Sonnet-3.5）相当，缩小了开源与闭源模型在该领域的差距。(2) 在事实性基准测试中，DeepSeek-V3 在 SimpleQA 和中文 SimpleQA 上均表现出优于其他开源模型的性能。尽管在英文事实知识（SimpleQA）上略逊于 GPT-4o 和 Claude-Sonnet-3.5，但在中文事实知识（中文 SimpleQA）上超越了这些模型，凸显了其在中文事实知识方面的优势。
- **代码、数学和推理**: (1) DeepSeek-V3 在所有非长链思维（CoT）的开源和闭源模型中，在数学相关基准测试上实现了最先进的性能。值得注意的是，它在特定基准测试（如 MATH-500）上甚至优于 o1-preview，展示了其强大的数学推理能力。(2) 在编码相关任务中，DeepSeek-V3 成为编码竞赛基准测试（如 LiveCodeBench）中表现最佳的模型，巩固了其在该领域的领先地位。在工程相关任务中，尽管 DeepSeek-V3 的表现略低于 Claude-Sonnet-3.5，但它仍然显著领先于所有其他模型，展示了其在多样化技术基准测试中的竞争力。

在本文的剩余部分，我们首先详细阐述了 DeepSeek-V3 的模型架构（第2节）。随后，我们介绍了我们的基础设施，包括计算集群、训练框架、对 FP8 训练的支持、推理部署策略以及对未来硬件设计的建议。接下来，我们描述了预训练过程，包括训练数据的构建、超参数设置、长上下文扩展技术、相关评估以及一些讨论（第4节）。之后，我们讨论了后训练的工作，包括监督微调（SFT）、强化学习（RL）、相应的评估和讨论（第5节）。最后，我们总结了这项工作，讨论了 DeepSeek-V3 的现有局限性，并提出了未来研究的潜在方向（第6节）。

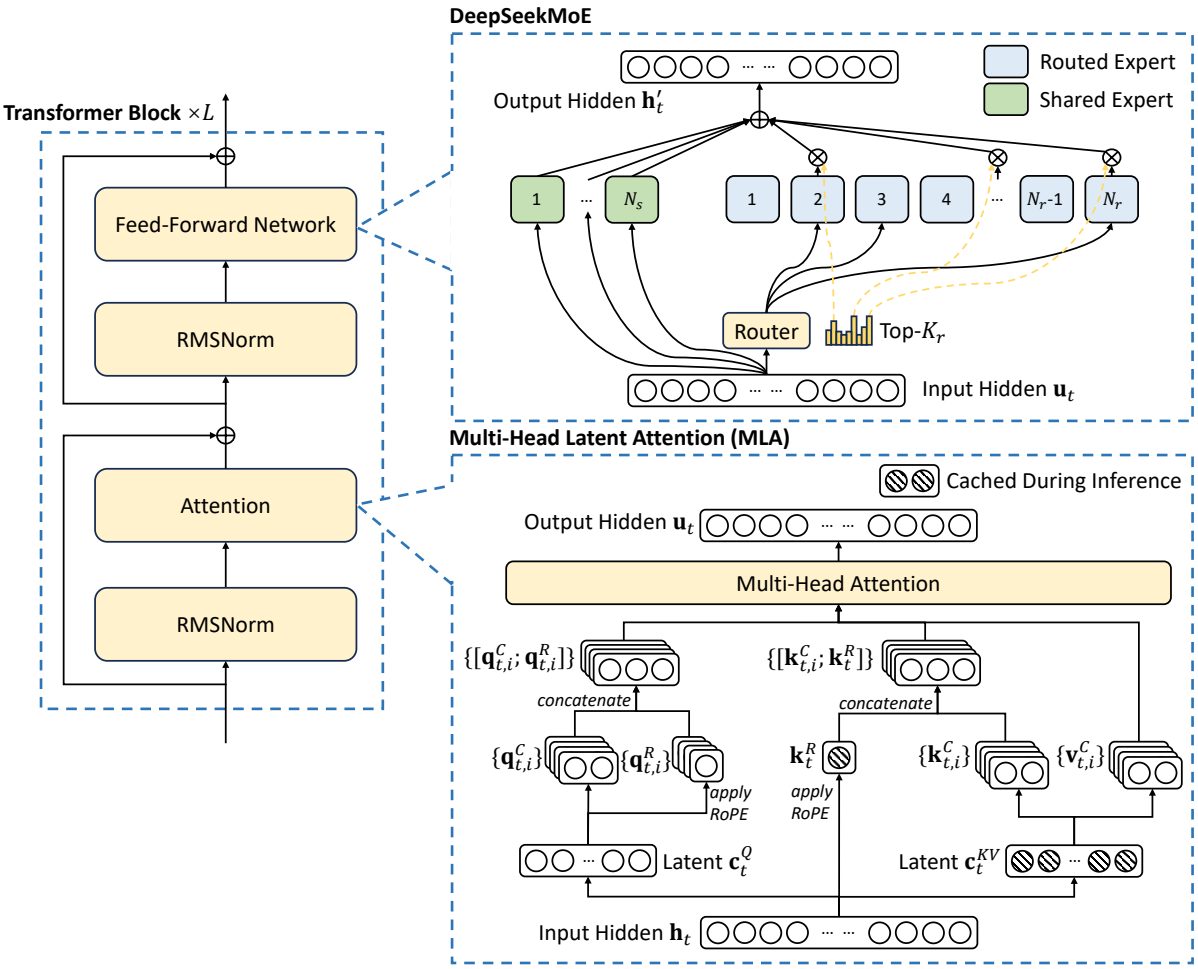

图 2: Illustration of the basic architecture of DeepSeek-V3. Following DeepSeek-V2, we adopt MLA and DeepSeekMoE for efficient inference and economical training.

2 架构

我们首先介绍 DeepSeek-V3 的基本架构，其特点是采用多头潜在注意力（Multi-head Latent Attention，MLA）以实现高效推理，以及 DeepSeekMoE 以实现经济训练。随后，我们提出了一种多标记预测（Multi-Token Prediction，MTP）训练目标，我们观察到它能够提升评估基准上的整体性能。对于其他未明确提及的小细节，DeepSeek-V3 遵循 DeepSeek-V2 的设置。

2.1 基本架构

DeepSeek-V3 的基本架构仍然在 Transformer 框架内。为了实现高效推理和经济训练，DeepSeek-V3 还采用了 MLA 和 DeepSeekMoE，这两者已在 DeepSeek-V2 中得到了充分验证。与 DeepSeek-V2 相比，一个例外是我们额外引入了一种无辅助损失的负载均衡策略，以减轻确保负载平衡所带来的性能下降。图 2 展示了 DeepSeek-V3 的基本架构，我们将在本节中简要回顾 MLA 和 DeepSeekMoE 的细节。

2.1.1 多头潜在注意力 (Multi-Head Latent Attention)

在注意力机制方面，DeepSeek-V3 采用了 MLA 架构。设 d 表示嵌入维度，n_h 表示注意力头的数量，d_h 表示每个头的维度，$\mathrm{h}_t \in \mathbb{R}^d$ 表示在给定注意力层中第 t 个标记的注意力输入。MLA 的核心是对注意力键和值进行低秩联合压缩，以减少推理过程中键值（Key-Value，KV）缓存的使用：

$$\boxed{\mathrm{c}_t^{KV}} = W^{DKV}\mathrm{h}_t, \tag{1}$$

$$[\mathrm{k}_{t,1}^C; \mathrm{k}_{t,2}^C; \ldots; \mathrm{k}_{t,n_h}^C] = \mathrm{k}_t^C = W^{UK}\mathrm{c}_t^{KV}, \tag{2}$$

$$\boxed{\mathrm{k}_t^R} = \mathrm{RoPE}(W^{KR}\mathrm{h}_t), \tag{3}$$

$$\mathrm{k}_{t,i} = [\mathrm{k}_{t,i}^C; \mathrm{k}_t^R], \tag{4}$$

$$[\mathrm{v}_{t,1}^C; \mathrm{v}_{t,2}^C; \ldots; \mathrm{v}_{t,n_h}^C] = \mathrm{v}_t^C = W^{UV}\mathrm{c}_t^{KV}, \tag{5}$$

其中 $\mathrm{c}_t^{KV} \in \mathbb{R}^{d_c}$ 是键和值的压缩潜在向量；$d_c(\ll d_h n_h)$ 表示 KV 压缩维度；$W^{DKV} \in \mathbb{R}^{d_c \times d}$ 表示下投影矩阵；$W^{UK}, W^{UV} \in \mathbb{R}^{d_h n_h \times d_c}$ 分别是键和值的上投影矩阵；$W^{KR} \in \mathbb{R}^{d_h^R \times d}$ 是用于生成携带旋转位置嵌入（Rotary Positional Embedding，RoPE）的解耦键的矩阵；$\mathrm{RoPE}(\cdot)$ 表示应用 RoPE 矩阵的操作；$[\cdot;\cdot]$ 表示连接操作。请注意，对于 MLA，只有蓝框中的向量（即 c_t^{KV} 和 k_t^R）需要在生成过程中缓存，这显著减少了 KV 缓存，同时保持与标准多头注意力（Multi-Head Attention，MHA）相当的性能。

对于注意力查询，我们也执行低秩压缩，这可以减少训练过程中的激活内存：

$$\mathrm{c}_t^Q = W^{DQ}\mathrm{h}_t, \tag{6}$$

$$[\mathrm{q}_{t,1}^C; \mathrm{q}_{t,2}^C; \ldots; \mathrm{q}_{t,n_h}^C] = \mathrm{q}_t^C = W^{UQ}\mathrm{c}_t^Q, \tag{7}$$

$$[\mathrm{q}_{t,1}^R; \mathrm{q}_{t,2}^R; \ldots; \mathrm{q}_{t,n_h}^R] = \mathrm{q}_t^R = \mathrm{RoPE}(W^{QR}\mathrm{c}_t^Q), \tag{8}$$

$$\mathrm{q}_{t,i} = [\mathrm{q}_{t,i}^C; \mathrm{q}_{t,i}^R], \tag{9}$$

其中 $\mathrm{c}_t^Q \in \mathbb{R}^{d_c'}$ 是查询的压缩潜在向量；$d_c'(\ll d_h n_h)$ 表示查询压缩维度；$W^{DQ} \in \mathbb{R}^{d_c' \times d}, W^{UQ} \in \mathbb{R}^{d_h n_h \times d_c'}$ 分别是查询的下投影和上投影矩阵；$W^{QR} \in \mathbb{R}^{d_h^R n_h \times d_c'}$ 是用于生成携带 RoPE 的解耦查询的矩阵。

最终，注意力查询 $(\mathrm{q}_{t,i})$、键 $(\mathrm{k}_{j,i})$ 和值 $(\mathrm{v}_{j,i}^C)$ 被组合以产生最终的注意力输出 u_t：

$$\mathrm{o}_{t,i} = \sum_{j=1}^{t} \mathrm{Softmax}_j\left(\frac{\mathrm{q}_{t,i}^T \mathrm{k}_{j,i}}{\sqrt{d_h + d_h^R}}\right)\mathrm{v}_{j,i}^C, \tag{10}$$

$$\mathrm{u}_t = W^O[\mathrm{o}_{t,1}; \mathrm{o}_{t,2}; \ldots; \mathrm{o}_{t,n_h}], \tag{11}$$

其中 $W^O \in \mathbb{R}^{d \times d_h n_h}$ 表示输出投影矩阵。

2.1.2 DeepSeekMoE with Auxiliary-Loss-Free Load Balancing

2.2 多 Token 预测 (Multi-Token Prediction)

3 基础设施

3.1 计算集群

3.2 训练框架

3.2.1 DualPipe and Computation-Communication Overlap

3.2.2 Efficient Implementation of Cross-Node All-to-All Communication

3.2.3 Extremely Memory Saving with Minimal Overhead

3.3 FP8 精度训练

3.4 推理和部署

3.4.1 Prefilling

3.4.2 解码

3.4.3 Communication Hardware

3.4.4 Compute Hardware

4 预训练

4.1 训练数据的构成

与 DeepSeek-V2 相比，我们通过增强数学和编程样本的比例来优化预训练语料库，同时扩展了多语言覆盖范围，超越了英语和中文。此外，我们的数据处理管道经过改进，以最小化冗余，同时保持语料库的多样性。受 Ding2024FewerTI 的启发，我们实施了文档打包方法以确保数据完整性，但在训练过程中未采用跨样本注意力掩码。最后，DeepSeek-V3 的训练语料库由 14.8T 高质量和多样化的标记组成。

在 DeepSeekCoder-V2 的训练过程中，我们观察到填充中间（Fill-in-Middle，FIM）策略并未损害下一个标记预测能力，同时使模型能够基于上下文线索准确预测中间文本。与 DeepSeekCoder-V2 一致，我们在 DeepSeek-V3 的预训练中也采用了 FIM 策略。具体来说，我们使用前缀-后缀-中间（Prefix-Suffix-Middle，PSM）框架来构建数据，如下所示：

$$\texttt{<|fim_begin|>}f_{\text{pre}}\texttt{<|fim_hole|>}f_{\text{suf}}\texttt{<|fim_end|>}f_{\text{middle}}\texttt{<|eos_token|>}.$$

该结构在文档级别应用，作为预打包过程的一部分。FIM 策略的应用比例为 0.1，符合 PSM 框架。

DeepSeek-V3 的分词器采用字节级 BPE，扩展词汇量为 128K 个标记。我们的分词器的预分词器和训练数据经过修改，以优化多语言压缩效率。此外，与 DeepSeek-V2 相比，新预分词器引入了将标点符号和换行符结合的标记。然而，当模型处理没有终止换行符的多行提示时，这种技巧可能会引入标记边界偏差，特别是在少样本评估提示中。为了解决这个问题，我们在训练过程中随机拆分一定比例的这种组合标记，从而使模型接触到更广泛的特殊情况，并减轻这种偏差。

4.2 超参数

4.3 长上下文扩展

4.4 评估

4.4.1 评估结果

4.5 讨论

4.5.1 Ablation Studies for Multi-Token Prediction

4.5.2 Ablation Studies for the Auxiliary-Loss-Free Balancing Strategy

4.5.3 Batch-Wise Load Balance VS. Sequence-Wise Load Balance

5 后训练

5.1 监督微调 (Supervised Fine-Tuning)

5.2 强化学习

5.2.1 奖励模型

5.2.2 组相对策略优化 (Group Relative Policy Optimization)

5.3 评估

5.3.1 评估设置

5.3.2 标准评估

5.3.3 Open-Ended Evaluation

5.3.4 DeepSeek-V3 as a Generative Reward Model

5.4 讨论

5.4.1 从 DeepSeek-R1 蒸馏

5.4.2 Self-Rewarding

5.4.3 Multi-Token Prediction Evaluation

6 结论，局限性和未来的方向

在本文中，我们介绍了 DeepSeek-V3，这是一个大型 MoE 语言模型，具有 671B 的总参数和 37B 的激活参数，训练数据量达到 14.8T 令牌。除了 MLA 和 DeepSeekMoE 架构外，它还开创了一种无辅助损失的负载平衡策略，并设定了多令牌预测训练目标，以实现更强的性能。

由于支持 FP8 训练和精细的工程优化，DeepSeek-V3 的训练具有成本效益。后训练阶段成功地从 DeepSeek-R1 系列模型中提炼了推理能力。全面评估表明，DeepSeek-V3 已成为当前最强的开源模型，并且在性能上与领先的闭源模型如 GPT-4o 和 Claude-3.5-Sonnet 相媲美。

尽管性能强大，但它仍保持了经济的训练成本。完整训练（包括预训练、上下文长度扩展和后训练）仅需 2.788M H800 GPU 小时。

尽管我们认可 DeepSeek-V3 的强大性能和成本效益，但我们也认识到它存在一些局限性，尤其是在部署方面。首先，为了确保高效的推理，DeepSeek-V3 的推荐部署单元相对较大，这可能会对小型团队造成负担。其次，尽管我们对 DeepSeek-V3 的部署策略已经实现了端到端生成速度比 DeepSeek-V2 快两倍以上，但仍存在进一步优化的潜力。幸运的是，随着更先进硬件的发展，这些局限性有望自然得到解决。

DeepSeek 始终坚持开放源代码模型的长期发展路线，旨在稳步接近 AGI（人工通用智能）的最终目标。未来，我们计划在以下方向进行战略性投资研究。

- 我们将持续研究和优化我们的模型架构，旨在进一步提高训练和推理效率，努力实现对无限上下文长度的高效支持。此外，我们还将尝试突破 Transformer 的架构限制，从而推动其建模能力的边界。
- 我们将不断迭代训练数据的数量和质量，并探索纳入额外训练信号来源，旨在推动数据在更广泛维度上的扩展。
- 我们将持续探索和迭代模型的深度思考能力，旨在通过扩展推理的长度和深度来增强模型的智能和解决问题的能力。
- 我们将探索更全面和多维度的模型评估方法，以防止在研究中倾向于优化固定的一组基准，这可能会对模型能力产生误导性的印象，并影响我们的基础评估。