DeepSeek-V3 技术报告

左元翻译

日期：February 6, 2025

摘　要

我们推出了 DeepSeek-V3，这是一个强大的混合专家（Mixture-of-Experts, MoE）语言模型，总参数量为 6710 亿，每个 token 激活的参数量为 370 亿。为了实现高效的推理和成本效益高的训练，DeepSeek-V3 采用了多头潜在注意力（Multi-head Latent Attention, MLA）和 DeepSeekMoE 架构，这些架构在 DeepSeek-V2 中得到了充分验证。此外，DeepSeek-V3 首创了一种无辅助损失的负载均衡策略，并设定了多 token 预测的训练目标，以实现更强的性能。我们在 14.8 万亿个多样且高质量的 token 上对 DeepSeek-V3 进行了预训练，随后通过监督微调（Supervised Fine-Tuning）和强化学习（Reinforcement Learning）阶段充分挖掘其潜力。综合评估表明，DeepSeek-V3 的表现优于其他开源模型，并与领先的闭源模型性能相当。尽管性能卓越，DeepSeek-V3 的完整训练仅需 278.8 万 H800 GPU 小时。此外，其训练过程非常稳定。在整个训练过程中，我们没有遇到任何不可恢复的损失突增或执行任何回滚操作。模型检查点可在https://github.com/deepseek-ai/DeepSeek-V3获取。

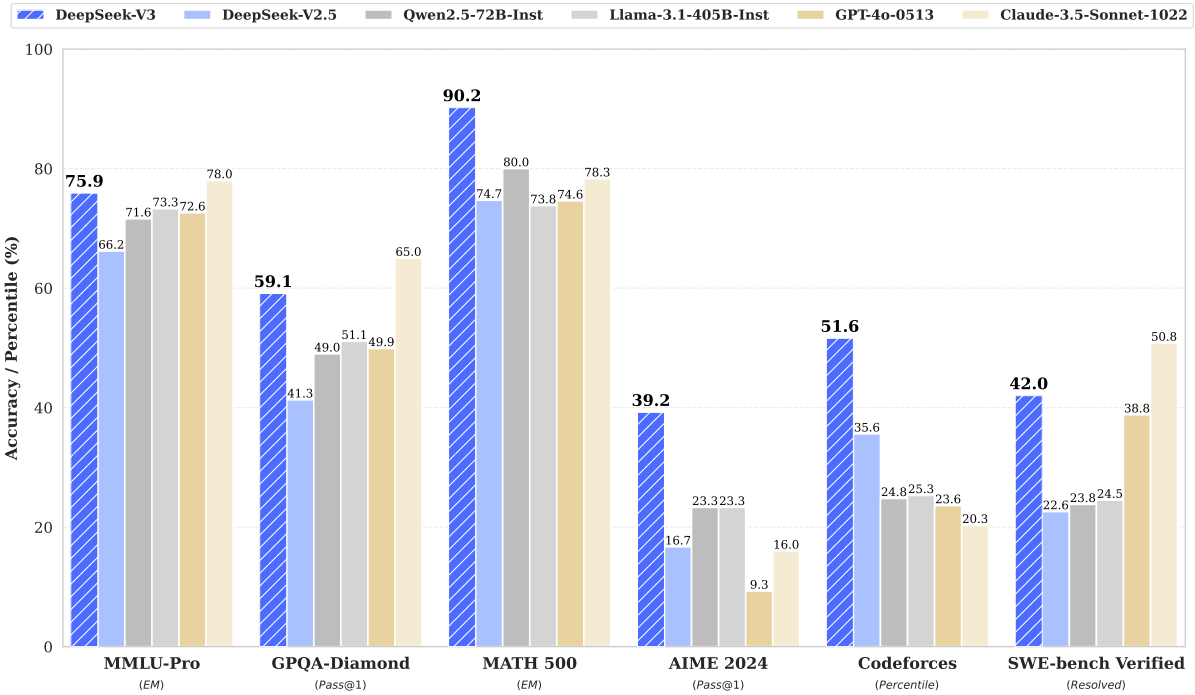

图 1: DeepSeek-V3 和竞品在性能基准测试中的比较。

目录

1 简介 **4**

2 架构 **6**

2.1 基本架构 6

2.1.1 多头潜在注意力 (Multi-Head Latent Attention) 6

2.1.2 DeepSeekMoE with Auxiliary-Loss-Free Load Balancing 7

2.2 多 Token 预测 (Multi-Token Prediction) 9

3 基础设施 **10**

3.1 计算集群 10

3.2 训练框架 10

3.2.1 DualPipe and Computation-Communication Overlap 10

3.2.2 跨节点全到全通信的高效实现, Efficient Implementation of Cross-Node All-to-All Communication 11

3.2.3 Extremely Memory Saving with Minimal Overhead 12

3.3 FP8 精度训练 13

3.3.1 混合精度框架 13

3.3.2 量化和乘法带来的精度提升 13

3.3.3 低精度存储和通信 15

3.4 推理和部署 16

3.4.1 Prefilling 16

3.4.2 解码 16

3.4.3 Communication Hardware 16

3.4.4 Compute Hardware 16

4 预训练 **16**

4.1 训练数据的构成 16

4.2 超参数 17

4.3 长上下文扩展 17

4.4 评估 17

4.4.1 评估结果 17

4.5 讨论 17

4.5.1 Ablation Studies for Multi-Token Prediction 17

4.5.2 Ablation Studies for the Auxiliary-Loss-Free Balancing Strategy 17

4.5.3 Batch-Wise Load Balance VS. Sequence-Wise Load Balance 17

5 后训练 **17**

5.1 监督微调 (Supervised Fine-Tuning) 17

5.2 强化学习 17

5.2.1 奖励模型 17

5.2.2 组相对策略优化 (Group Relative Policy Optimization) 17

5.3 评估 17

5.3.1 评估设置 17

5.3.2 标准评估 17
5.3.3 开放式评估 18
5.3.4 DeepSeek-V3 作为通用的奖励模型 18
5.4 讨论 19
5.4.1 从 DeepSeek-R1 蒸馏 19
5.4.2 Self-Rewarding 19
5.4.3 Multi-Token Prediction Evaluation 19

6 结论，局限性和未来的方向 19

A Ablation Studies for Low-Precision Training 21
A.1 FP8 v.s. BF16 Training 21
A.2 Discussion About Block-Wise Quantization 21

B Expert Specialization Patterns of the 16B Aux-Loss-Based and Aux-Loss-Free Models 21

Training Costs	Pre-Training	Context Extension	Post-Training	Total
in H800 GPU Hours	2664K	119K	5K	2788K
in USD	$5.328M	$0.238M	$0.01M	$5.576M

表 1: DeepSeek-V3 的训练花费，假设 H800 每个 GPU 小时的租赁费用是 $2。

1 简介

近年来，大语言模型（Large Language Models, LLMs）正在经历快速的迭代和演进，逐步缩小与通用人工智能（Artificial General Intelligence, AGI）的差距。除了闭源模型外，开源模型，包括 DeepSeek 系列、LLaMA 系列、Qwen 系列和 Mistral 系列，也在取得显著进展，努力缩小与闭源模型的差距。为了进一步突破开源模型的能力边界，我们扩大了模型规模，并推出了 DeepSeek-V3，这是一个拥有 6710 亿参数的大型混合专家（Mixture-of-Experts, MoE）模型，其中每个 token 激活的参数量为 370 亿。

以前瞻性的视角，我们始终致力于实现强大的模型性能和经济的成本。因此，在架构方面，DeepSeek-V3 仍然采用多头潜在注意力（MLA）以实现高效推理，以及 DeepSeekMoE 以实现成本效益高的训练。这两种架构在 DeepSeek-V2 中得到了验证，证明了它们在保持强大模型性能的同时实现高效训练和推理的能力。除了基础架构外，我们还实施了两项额外策略以进一步增强模型能力。首先，DeepSeek-V3 首创了一种无辅助损失的负载均衡策略，旨在最小化因鼓励负载均衡而对模型性能产生的负面影响。其次，DeepSeek-V3 采用了多 token 预测的训练目标，我们观察到这可以提升评估基准上的整体性能。

为了实现高效的训练，我们支持 FP8 混合精度训练，并对训练框架进行了全面优化。低精度训练已成为高效训练的一种有前景的解决方案，其发展与硬件能力的进步密切相关。在这项工作中，我们引入了 FP8 混合精度训练框架，并首次在超大规模模型上验证了其有效性。通过支持 FP8 计算和存储，我们实现了训练加速和 GPU 内存使用量的减少。在训练框架方面，我们设计了 DualPipe 算法以实现高效的流水线并行，该算法减少了流水线气泡，并通过计算-通信重叠隐藏了训练过程中的大部分通信。这种重叠确保了随着模型的进一步扩展，只要我们保持恒定的计算与通信比率，我们仍然可以在节点间使用细粒度的专家，同时实现近乎零的全对全通信开销。此外，我们还开发了高效的跨节点全对全通信内核，以充分利用 InfiniBand（IB）和 NVLink 的带宽。此外，我们精心优化了内存占用，使得在不使用昂贵的张量并行的情况下训练 DeepSeek-V3 成为可能。结合这些努力，我们实现了高效的训练。

在预训练阶段，我们在 14.8 万亿个高质量且多样化的 token 上训练了 DeepSeek-V3。预训练过程非常稳定。在整个训练过程中，我们没有遇到任何不可恢复的损失突增，也没有进行任何回滚操作。接下来，我们对 DeepSeek-V3 进行了两阶段的上下文长度扩展。在第一阶段，最大上下文长度扩展到 32K，在第二阶段进一步扩展到 128K。随后，我们对 DeepSeek-V3 的基础模型进行了后训练，包括监督微调（Supervised Fine-Tuning, SFT）和强化学习（Reinforcement Learning, RL），以使其与人类偏好对齐并进一步释放其潜力。在后训练阶段，我们从 DeepSeek-R1 系列模型中蒸馏了推理能力，同时精心平衡了模型准确性和生成长度之间的关系。

我们在广泛的基准测试上对 DeepSeek-V3 进行了评估。尽管训练成本经济，综合评估表明，DeepSeek-V3-Base 已成为当前最强的开源基础模型，尤其是在代码和数学领域。其聊天版本也在标准基准和开放式基准测试中优于其他开源模型，并与领先的闭源模型（包括 GPT-4o 和 Claude-3.5-Sonnet）性能相当。

最后，我们再次强调 DeepSeek-V3 的经济训练成本，总结在表 1中，这是通过我们对算法、框架和硬件的优化协同设计实现的。在预训练阶段，每万亿 token 的训练仅需 18 万 H800 GPU 小时，即在我们拥有 2048 个 H800 GPU 的集群上仅需 3.7 天。因此，我们的预训练阶段在不到两个月内完成，并消耗了 266.4 万 GPU 小时。结合上下文长度扩展所需的 11.9 万 GPU 小时和后训练的 0.5 万 GPU 小时，DeepSeek-V3 的完整训练仅需 278.8 万 GPU 小时。假设 H800 GPU 的租赁价格为每小时 2 美元，我们的总训练成本仅为 557.6 万美元。需要注意的是，上述成本仅包括 DeepSeek-V3 的官方训练，不包括在架构、算法或数据

上的前期研究和消融实验相关成本。

我们主要的贡献包括：

架构：创新的负载均衡策略和训练目标

- 在 DeepSeek-V2 的高效架构基础上，我们首创了一种无辅助损失的负载均衡策略，最大限度地减少了因鼓励负载均衡而导致的性能下降。
- 我们研究了多 token 预测（Multi-Token Prediction, MTP）目标，并证明其对模型性能有益。它还可以用于推测解码（speculative decoding）以实现推理加速。

预训练：通往终极的训练效率

- 我们设计了一个 FP8 混合精度训练框架，并首次在超大规模模型上验证了 FP8 训练的可行性和有效性。
- 通过算法、框架和硬件的协同设计，我们克服了跨节点 MoE 训练中的通信瓶颈，实现了近乎完全的计算-通信重叠。这显著提高了我们的训练效率并降低了训练成本，使我们能够在不增加额外开销的情况下进一步扩大模型规模。
- 仅以 266.4 万 H800 GPU 小时的经济成本，我们完成了 DeepSeek-V3 在 14.8 万亿 token 上的预训练，生成了当前最强的开源基础模型。预训练后的后续训练阶段仅需 10 万 GPU 小时。

后训练：从 DeepSeek-R1 进行知识蒸馏

- 我们引入了一种创新方法，将长思维链（Chain-of-Thought, CoT）模型（特别是 DeepSeek R1 系列模型之一）的推理能力蒸馏到标准 LLM（尤其是 DeepSeek-V3）中。我们的管道巧妙地将 R1 的验证和反思模式融入 DeepSeek-V3，显著提升了其推理性能。同时，我们还控制了 DeepSeek-V3 的输出风格和长度。

核心评估结果总结

- **知识**: (1) 在教育类基准测试（如 MMLU、MMLU-Pro 和 GPQA）上，DeepSeek-V3 优于所有其他开源模型，在 MMLU 上得分为 88.5，在 MMLU-Pro 上得分为 75.9，在 GPQA 上得分为 59.1。其性能与领先的闭源模型（如 GPT-4o 和 Claude-Sonnet-3.5）相当，缩小了开源与闭源模型在该领域的差距。(2) 在事实性基准测试中，DeepSeek-V3 在 SimpleQA 和中文 SimpleQA 上均表现出优于其他开源模型的性能。尽管在英文事实知识（SimpleQA）上略逊于 GPT-4o 和 Claude-Sonnet-3.5，但在中文事实知识（中文 SimpleQA）上超越了这些模型，凸显了其在中文事实知识方面的优势。
- **代码、数学和推理**: (1) DeepSeek-V3 在所有非长链思维（CoT）的开源和闭源模型中，在数学相关基准测试上实现了最先进的性能。值得注意的是，它在特定基准测试（如 MATH-500）上甚至优于 o1-preview，展示了其强大的数学推理能力。(2) 在编码相关任务中，DeepSeek-V3 成为编码竞赛基准测试（如 LiveCodeBench）中表现最佳的模型，巩固了其在该领域的领先地位。在工程相关任务中，尽管 DeepSeek-V3 的表现略低于 Claude-Sonnet-3.5，但它仍然显著领先于所有其他模型，展示了其在多样化技术基准测试中的竞争力。

在本文的剩余部分，我们首先详细阐述了 DeepSeek-V3 的模型架构（第2节）。随后，我们介绍了我们的基础设施，包括计算集群、训练框架、对 FP8 训练的支持、推理部署策略以及对未来硬件设计的建议。接下来，我们描述了预训练过程，包括训练数据的构建、超参数设置、长上下文扩展技术、相关评估以及一些讨论（第4节）。之后，我们讨论了后训练的工作，包括监督微调（SFT）、强化学习（RL）、相应的评估和讨论（第5节）。最后，我们总结了这项工作，讨论了 DeepSeek-V3 的现有局限性，并提出了未来研究的潜在方向（第6节）。

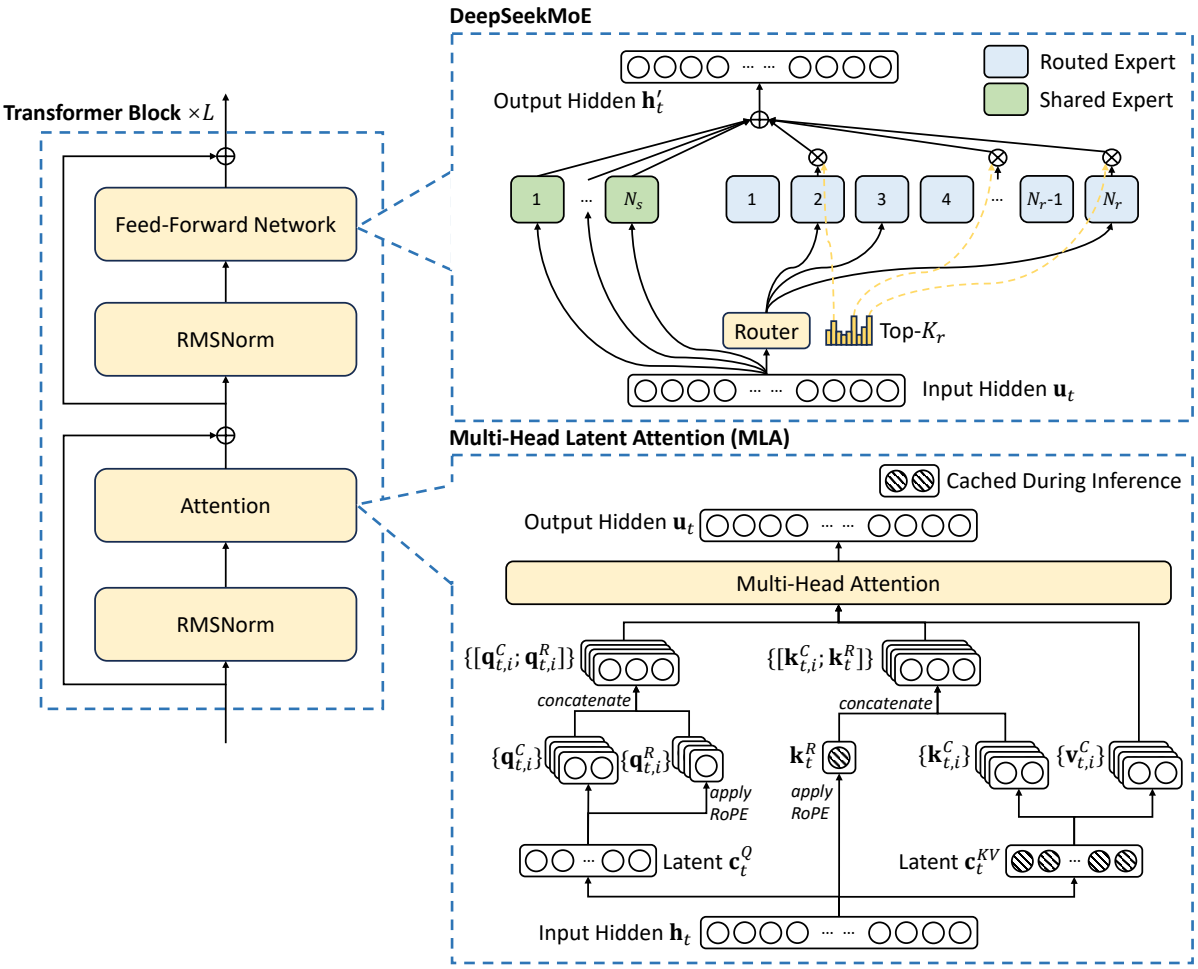

图 2: Illustration of the basic architecture of DeepSeek-V3. Following DeepSeek-V2, we adopt MLA and DeepSeekMoE for efficient inference and economical training.

2 架构

我们首先介绍 DeepSeek-V3 的基本架构，其特点是采用多头潜在注意力（Multi-head Latent Attention，MLA）以实现高效推理，以及 DeepSeekMoE 以实现经济训练。随后，我们提出了一种多 Token 预测（Multi-Token Prediction，MTP）训练目标，我们观察到它能够提升评估基准上的整体性能。对于其他未明确提及的小细节，DeepSeek-V3 遵循 DeepSeek-V2 的设置。

2.1 基本架构

DeepSeek-V3 的基本架构仍然在 Transformer 框架内。为了实现高效推理和经济训练，DeepSeek-V3 还采用了 MLA 和 DeepSeekMoE，这两者已在 DeepSeek-V2 中得到了充分验证。与 DeepSeek-V2 相比，一个例外是我们额外引入了一种无辅助损失的负载均衡策略，以减轻确保负载平衡所带来的性能下降。图 2 展示了 DeepSeek-V3 的基本架构，我们将在本节中简要回顾 MLA 和 DeepSeekMoE 的细节。

2.1.1 多头潜在注意力 (Multi-Head Latent Attention)

在注意力机制方面，DeepSeek-V3 采用了 MLA 架构。设 d 表示嵌入维度，n_h 表示注意力头的数量，d_h 表示每个头的维度，$\mathrm{h}_t \in \mathbb{R}^d$ 表示在给定注意力层中第 t 个标记的注意力输入。MLA 的核心是对注意力键和值进行低秩联合压缩，以减少推理过程中键值（Key-Value，KV）缓存的使用：

$$\boxed{\mathrm{c}_t^{KV}} = W^{DKV}\mathrm{h}_t, \tag{1}$$

$$[\mathrm{k}_{t,1}^C; \mathrm{k}_{t,2}^C; \ldots; \mathrm{k}_{t,n_h}^C] = \mathrm{k}_t^C = W^{UK}\mathrm{c}_t^{KV}, \tag{2}$$

$$\boxed{\mathrm{k}_t^R} = \mathrm{RoPE}(W^{KR}\mathrm{h}_t), \tag{3}$$

$$\mathrm{k}_{t,i} = [\mathrm{k}_{t,i}^C; \mathrm{k}_t^R], \tag{4}$$

$$[\mathrm{v}_{t,1}^C; \mathrm{v}_{t,2}^C; \ldots; \mathrm{v}_{t,n_h}^C] = \mathrm{v}_t^C = W^{UV}\mathrm{c}_t^{KV}, \tag{5}$$

其中 $\mathrm{c}_t^{KV} \in \mathbb{R}^{d_c}$ 是键和值的压缩潜在向量；$d_c(\ll d_h n_h)$ 表示 KV 压缩维度；$W^{DKV} \in \mathbb{R}^{d_c \times d}$ 表示下投影矩阵；$W^{UK}, W^{UV} \in \mathbb{R}^{d_h n_h \times d_c}$ 分别是键和值的上投影矩阵；$W^{KR} \in \mathbb{R}^{d_h^R \times d}$ 是用于生成携带旋转位置嵌入（Rotary Positional Embedding，RoPE）的解耦键的矩阵；$\mathrm{RoPE}(\cdot)$ 表示应用 RoPE 矩阵的操作；$[\cdot;\cdot]$ 表示连接操作。请注意，对于 MLA，只有蓝框中的向量（即 c_t^{KV} 和 k_t^R）需要在生成过程中缓存，这显著减少了 KV 缓存，同时保持与标准多头注意力（Multi-Head Attention，MHA）相当的性能。

对于注意力查询，我们也执行低秩压缩，这可以减少训练过程中的激活内存：

$$\mathrm{c}_t^Q = W^{DQ}\mathrm{h}_t, \tag{6}$$

$$[\mathrm{q}_{t,1}^C; \mathrm{q}_{t,2}^C; \ldots; \mathrm{q}_{t,n_h}^C] = \mathrm{q}_t^C = W^{UQ}\mathrm{c}_t^Q, \tag{7}$$

$$[\mathrm{q}_{t,1}^R; \mathrm{q}_{t,2}^R; \ldots; \mathrm{q}_{t,n_h}^R] = \mathrm{q}_t^R = \mathrm{RoPE}(W^{QR}\mathrm{c}_t^Q), \tag{8}$$

$$\mathrm{q}_{t,i} = [\mathrm{q}_{t,i}^C; \mathrm{q}_{t,i}^R], \tag{9}$$

其中 $\mathrm{c}_t^Q \in \mathbb{R}^{d_c'}$ 是查询的压缩潜在向量；$d_c'(\ll d_h n_h)$ 表示查询压缩维度；$W^{DQ} \in \mathbb{R}^{d_c' \times d}, W^{UQ} \in \mathbb{R}^{d_h n_h \times d_c'}$ 分别是查询的下投影和上投影矩阵；$W^{QR} \in \mathbb{R}^{d_h^R n_h \times d_c'}$ 是用于生成携带 RoPE 的解耦查询的矩阵。

最终，注意力查询 $(\mathrm{q}_{t,i})$、键 $(\mathrm{k}_{j,i})$ 和值 $(\mathrm{v}_{j,i}^C)$ 被组合以产生最终的注意力输出 u_t：

$$\mathrm{o}_{t,i} = \sum_{j=1}^{t} \mathrm{Softmax}_j\left(\frac{\mathrm{q}_{t,i}^T \mathrm{k}_{j,i}}{\sqrt{d_h + d_h^R}}\right)\mathrm{v}_{j,i}^C, \tag{10}$$

$$\mathrm{u}_t = W^O[\mathrm{o}_{t,1}; \mathrm{o}_{t,2}; \ldots; \mathrm{o}_{t,n_h}], \tag{11}$$

其中 $W^O \in \mathbb{R}^{d \times d_h n_h}$ 表示输出投影矩阵。

2.1.2 DeepSeekMoE with Auxiliary-Loss-Free Load Balancing

基于 DeepSeekMoE 的基本架构。 对于前馈网络（FFNs），DeepSeek-V3 采用了 DeepSeekMoE 架构。与传统的 MoE 架构（如 GShard）相比，DeepSeekMoE 使用了更细粒度的专家，并将一些专家隔离为共享专家。设 u_t 表示第 t 个 token 的 FFN 输入，我们计算 FFN 输出 h_t' 如下：

$$\mathrm{h}_t' = \mathrm{u}_t + \sum_{i=1}^{N_s} \mathrm{FFN}_i^{(s)}(\mathrm{u}_t) + \sum_{i=1}^{N_r} g_{i,t}\,\mathrm{FFN}_i^{(r)}(\mathrm{u}_t), \tag{12}$$

$$g_{i,t} = \frac{g_{i,t}'}{\sum_{j=1}^{N_r} g_{j,t}'}, \tag{13}$$

$$g_{i,t}' = \begin{cases} s_{i,t}, & s_{i,t} \in \mathrm{Topk}(\{s_{j,t} | 1 \le j \le N_r\}, K_r), \\ 0, & \text{otherwise}, \end{cases} \tag{14}$$

$$s_{i,t} = \mathrm{Sigmoid}\left(\mathrm{u}_t{}^T \mathrm{e}_i\right), \tag{15}$$

其中 N_s 和 N_r 分别表示共享专家和路由专家的数量；$\mathrm{FFN}_i^{(s)}(\cdot)$ 和 $\mathrm{FFN}_i^{(r)}(\cdot)$ 分别表示第 i 个共享专家和第 i 个路由专家；K_r 表示激活的路由专家数量；$g_{i,t}$ 是第 i 个专家的门控值；$s_{i,t}$ 是 token 与专家的亲和度；e_i 是第 i 个路由专家的中心向量；$\mathrm{Topk}(\cdot, K)$ 表示包含 K 个最高分数的集合，这些分数是为第 t 个 token 和所有路由专家计算的亲和度分数。与 DeepSeek-V2 略有不同，DeepSeek-V3 使用 sigmoid 函数来计算亲和度分数，并在所有选定的亲和度分数之间应用归一化，以生成门控值。

无辅助损失的负载平衡。 对于 MoE 模型，不平衡的专家负载会导致路由崩溃，并在专家并行的场景中降低计算效率。传统的解决方案通常依赖于辅助损失来避免负载不平衡。然而，过大的辅助损失会损害模型性能。为了在负载平衡和模型性能之间实现更好的权衡，我们首创了一种无辅助损失的负载平衡策略，以确保负载平衡。

具体来说，我们为每个专家引入一个偏置项 b_i，并将其添加到相应的亲和度分数 $s_{i,t}$ 中，以确定 top-K 路由：

$$g'_{i,t} = \begin{cases} s_{i,t}, & s_{i,t} + b_i \in \mathrm{Topk}(\{s_{j,t} + b_j | 1 \le j \le N_r\}, K_r), \\ 0, & \text{otherwise}. \end{cases} \tag{16}$$

请注意，偏置项仅用于路由。门控值将与 FFN 输出相乘，仍然来源于原始的亲和度分数 $s_{i,t}$。在训练过程中，我们持续监控每个训练步骤整个批次的专家负载。在每个步骤结束时，如果相应的专家超载，我们将偏置项减少 γ；如果相应的专家负载不足，则增加 γ，其中 γ 是一个称为偏置更新速度的超参数。通过动态调整，DeepSeek-V3 在训练过程中保持专家负载平衡，并且实现了比通过纯辅助损失鼓励负载平衡的模型更好的性能。

互补的序列级辅助损失。 虽然 DeepSeek-V3 主要依赖于无辅助损失的负载平衡策略，但为了防止单个序列内部的极端不平衡，我们还采用了互补的序列级平衡损失：

$$\mathcal{L}_{\mathrm{Bal}} = \alpha \sum_{i=1}^{N_r} f_i P_i, \tag{17}$$

$$f_i = \frac{N_r}{K_r T} \sum_{t=1}^{T} \mathbb{1}\left(s_{i,t} \in \mathrm{Topk}(\{s_{j,t} | 1 \le j \le N_r\}, K_r)\right), \tag{18}$$

$$s'_{i,t} = \frac{s_{i,t}}{\sum_{j=1}^{N_r} s_{j,t}}, \tag{19}$$

$$P_i = \frac{1}{T} \sum_{t=1}^{T} s'_{i,t}, \tag{20}$$

其中平衡因子 α 是一个超参数，对于 DeepSeek-V3 将被赋予一个极小的值；$\mathbb{1}(\cdot)$ 表示指示函数；T 表示序列中的 token 数量。序列级平衡损失鼓励每个序列的专家负载保持平衡。

节点限制路由。 与 DeepSeek-V2 使用的设备限制路由类似，DeepSeek-V3 也采用了一种受限路由机制，以限制训练过程中的通信成本。简而言之，我们确保每个 token 最多只会被发送到 M 个节点，这些节点是根据分布在每个节点上的专家的最高 $\frac{K_r}{M}$ 个亲和度分数之和进行选择的。在这个约束下，我们的 MoE 训练框架几乎可以实现完全的计算-通信重叠。

无 Token 丢弃。 由于有效的负载平衡策略，DeepSeek-V3 在整个训练过程中保持了良好的负载平衡。因此，DeepSeek-V3 在训练过程中不会丢弃任何 tokens。此外，我们还实施了特定的部署策略，以确保推理负载平衡，因此 DeepSeek-V3 在推理过程中也不会丢弃 tokens。

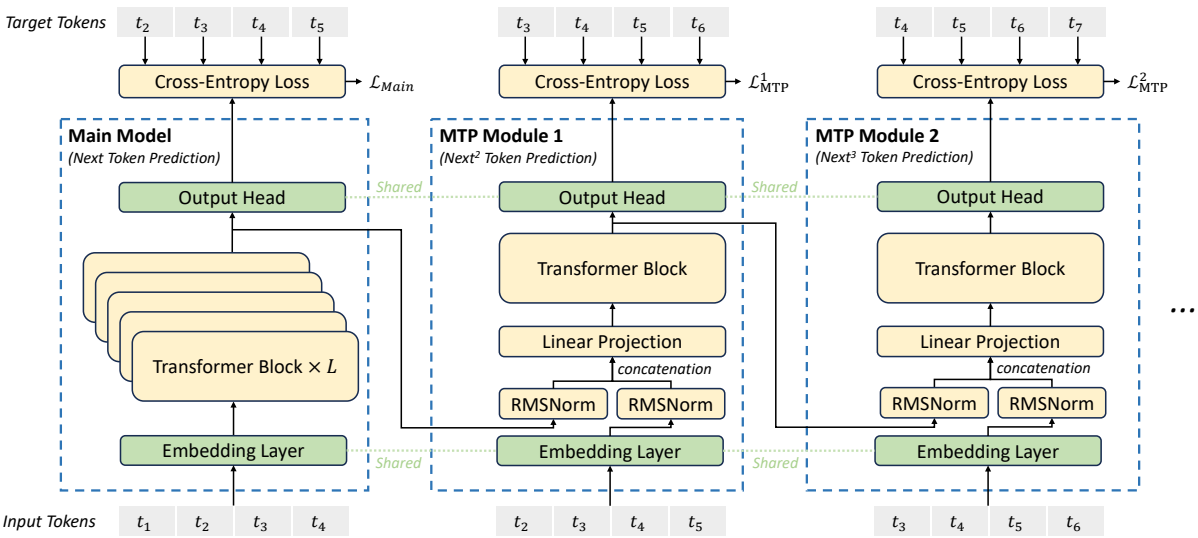

图 3: Illustration of our Multi-Token Prediction (MTP) implementation. We keep the complete causal chain for the prediction of each token at each depth.

2.2 多 Token 预测 (Multi-Token Prediction)

受到 meta_mtp 的启发，我们为 DeepSeek-V3 研究并设定了多 token 预测（MTP）目标，该目标将预测范围扩展到每个位置的多个未来 token。一方面，MTP 目标密集化了训练信号，可能提高数据效率。另一方面，MTP 可能使模型能够提前规划其表示，以更好地预测未来的 token。图 3 展示了我们对 MTP 的实现。与 meta_mtp 并行预测 D 个额外 token 使用独立输出头不同，我们是顺序预测额外 token，并在每个预测深度保持完整的因果链。在本节中，我们将介绍 MTP 实现的详细信息。

MTP 模块。 具体来说，我们的 MTP 实现使用 D 个顺序模块来预测 D 个额外的 token。第 k 个 MTP 模块由一个共享的嵌入层 $\mathrm{Emb}(\cdot)$、一个共享的输出头 $\mathrm{OutHead}(\cdot)$、一个 Transformer 块 $\mathrm{TRM}_k(\cdot)$ 和一个投影矩阵 $M_k \in \mathbb{R}^{d\times 2d}$ 组成。对于第 i 个输入 token t_i，在第 k 个预测深度，我们首先将第 $(k-1)$ 深度的第 i 个 token 的表示 $\mathrm{h}_i^{k-1} \in \mathbb{R}^d$ 与第 $(i+k)$ 个 token 的嵌入 $Emb(t_{i+k}) \in \mathbb{R}^d$ 通过线性投影结合起来：

$$\mathrm{h}_i'^k = M_k[\mathrm{RMSNorm}(\mathrm{h}_i^{k-1}); \mathrm{RMSNorm}(\mathrm{Emb}(t_{i+k}))], \tag{21}$$

其中 $[\cdot;\cdot]$ 表示拼接。

特别地，当 $k=1$ 时，h_i^{k-1} 指的是主模型给出的表示。注意，对于每个 MTP 模块，其嵌入层与主模型共享。结合后的 $\mathrm{h}_i'^k$ 作为第 k 个深度 Transformer 块的输入，以生成当前深度的输出表示 h_i^k：

$$\mathrm{h}_{1:T-k}^k = \mathrm{TRM}_k(\mathrm{h}_{1:T-k}'^k), \tag{22}$$

其中 T 表示输入序列的长度，$_{i:j}$ 表示切片操作（包括左右边界）。最后，以 h_i^k 作为输入，共享的输出头将计算第 k 个额外预测 token 的概率分布 $P_{i+1+k}^k \in \mathbb{R}^V$，其中 V 是词汇表的大小：

$$P_{i+k+1}^k = \mathrm{OutHead}(\mathrm{h}_i^k). \tag{23}$$

输出头 $\mathrm{OutHead}(\cdot)$ 将表示线性映射到 logits，并随后应用 $\mathrm{Softmax}(\cdot)$ 函数以计算第 k 个额外 token 的预测概率。此外，对于每个 MTP 模块，其输出头也与主模型共享。我们保持预测的因果链的原则类似于 EAGLE，但其主要目标是投机解码，而我们利用 MTP 来改善训练。

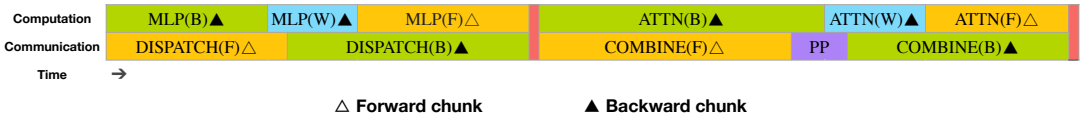

图 4: Overlapping strategy for a pair of individual forward and backward chunks (the boundaries of the transformer blocks are not aligned). Orange denotes forward, green denotes "backward for input", blue denotes "backward for weights", purple denotes PP communication, and red denotes barriers. Both all-to-all and PP communication can be fully hidden.

MTP 训练目标。 对于每个预测深度，我们计算交叉熵损失 $\mathcal{L}_{\text{MTP}}^{k}$：

$$\mathcal{L}_{\text{MTP}}^{k} = \text{CrossEntropy}(P_{2+k:T+1}^{k}, t_{2+k:T+1}) = -\frac{1}{T}\sum_{i=2+k}^{T+1} \log P_i^k[t_i], \tag{24}$$

其中 T 表示输入序列的长度，t_i 表示第 i 个位置的真实 token，$P_i^k[t_i]$ 表示由第 k 个 MTP 模块给出的 t_i 的相应预测概率。最后，我们计算所有深度的 MTP 损失的平均值，并乘以一个权重因子 λ，以获得整体 MTP 损失 $\mathcal{L}_{\text{MTP}}$，作为 DeepSeek-V3 的额外训练目标：

$$\mathcal{L}_{\text{MTP}} = \frac{\lambda}{D}\sum_{k=1}^{D} \mathcal{L}_{\text{MTP}}^{k}. \tag{25}$$

推理中的 MTP。 我们的 MTP 策略主要旨在提高主模型的性能，因此在推理过程中，我们可以直接丢弃 MTP 模块，主模型可以独立且正常地运行。此外，我们还可以将这些 MTP 模块重新用于投机解码，以进一步提高生成的延迟性能。

3 基础设施

3.1 计算集群

DeepSeek-V3 在一个配备 2048 个 NVIDIA H800 GPU 的集群上进行训练。每个 H800 集群节点包含 8 个通过 NVLink 和 NVSwitch 连接的 GPU。不同节点之间使用 InfiniBand（IB）互连来促进通信。

3.2 训练框架

DeepSeek-V3 的训练得益于 HAI-LLM 框架，这是我们工程师从零开始打造的高效轻量级训练框架。总体而言，DeepSeek-V3 应用了 16 路管道并行（PP）、跨越 8 个节点的 64 路专家并行（EP）和 ZeRO-1 数据并行（DP）。

为了促进 DeepSeek-V3 的高效训练，我们实施了细致的工程优化。首先，我们设计了 DualPipe 算法以实现高效的管道并行。与现有的 PP 方法相比，DualPipe 具有更少的管道气泡。更重要的是，它在前向和反向过程中重叠计算和通信阶段，从而解决了跨节点专家并行带来的高通信开销问题。其次，我们开发了高效的跨节点全到全通信内核，以充分利用 IB 和 NVLink 带宽，并节省专用于通信的流处理器（SM）。最后，我们在训练过程中仔细优化了内存占用，从而使我们能够在不使用昂贵的张量并行（TP）的情况下训练 DeepSeek-V3。

3.2.1 DualPipe and Computation-Communication Overlap

对于 DeepSeek-V3，跨节点专家并行引入的通信开销导致计算与通信的比率约为 1:1，这使得效率低下。为了解决这一挑战，我们设计了一种创新的管道并行算法，称为 DualPipe，它不仅通过有效重叠前

图 5: Example DualPipe scheduling for 8 PP ranks and 20 micro-batches in two directions. The micro-batches in the reverse direction are symmetric to those in the forward direction, so we omit their batch ID for illustration simplicity. Two cells enclosed by a shared black border have mutually overlapped computation and communication.

Method	Bubble	Parameter	Activation
1F1B	$(PP-1)(F+B)$	$1\times$	PP
ZB1P	$(PP-1)(F+B-2W)$	$1\times$	PP
DualPipe (Ours)	$(\frac{PP}{2}-1)(F\&B+B-3W)$	$2\times$	$PP+1$

表 2: Comparison of pipeline bubbles and memory usage across different pipeline parallel methods. F denotes the execution time of a forward chunk, B denotes the execution time of a full backward chunk, W denotes the execution time of a "backward for weights" chunk, and $F\&B$ denotes the execution time of two mutually overlapped forward and backward chunks.

向和反向计算-通信阶段来加速模型训练，还减少了管道气泡的产生。

DualPipe 的关键思想是在一对前向和反向块内重叠计算和通信。具体来说，我们将每个块分为四个组件：`attention`、`all-to-all dispatch`、`MLP` 和 `all-to-all combine`。特别地，对于反向块，`attention` 和 `MLP` 进一步拆分为两个部分：`backward for input` 和 `backward for weights`，类似于 ZeroBubble。此外，我们还有一个 `PP communication` 组件。如图 4 所示，对于一对前向和反向块，我们重新排列这些组件，并手动调整专用于通信与计算的 GPU SM 比例。在这种重叠策略中，我们可以确保在执行期间，所有到所有（all-to-all）和管道并行（PP）通信可以完全隐藏。

鉴于高效的重叠策略，完整的 DualPipe 调度如图 5 所示。它采用双向管道调度，同时从管道的两端输入微批次，并且大量通信可以完全重叠。这种重叠还确保了，随着模型的进一步扩展，只要我们保持恒定的计算与通信比率，就可以在节点之间使用细粒度的专家，同时实现接近零的全到全通信开销。

此外，即使在没有重通信负担的更一般场景中，DualPipe 仍然表现出效率优势。在表 2 中，我们总结了不同 PP 方法的管道气泡和内存使用情况。如表中所示，与 ZB1P 和 1F1B 相比，DualPipe 显著减少了管道气泡，同时仅将峰值激活内存增加了 $\frac{1}{PP}$ 倍。

尽管 DualPipe 需要保留两份模型参数的副本，但由于我们在训练中使用了较大的专家并行（EP）规模，这并不会显著增加内存消耗。与 Chimera 相比，DualPipe 仅要求管道阶段和微批次可被 2 整除，而不要求微批次可被管道阶段整除。此外，对于 DualPipe，随着微批次数量的增加，管道气泡和激活内存都不会增加。

3.2.2 跨节点全到全通信的高效实现，Efficient Implementation of Cross-Node All-to-All Communication

为了确保 DualPipe 的计算性能，我们定制了高效的跨节点全到全通信内核（包括调度和合并），以节省用于通信的流处理器（SM）数量。这些内核的实现与我们的 MoE 门控算法和集群的网络拓扑共同设计。

具体来说，在我们的集群中，跨节点的 GPU 通过 IB 完全互连，而节点内的通信则通过 NVLink 处理。NVLink 的带宽为 160 GB/s，约为 IB（50 GB/s）的 3.2 倍。为了有效利用 IB 和 NVLink 的不同带宽，我们限制每个令牌最多调度到 4 个节点，从而减少 IB 流量。

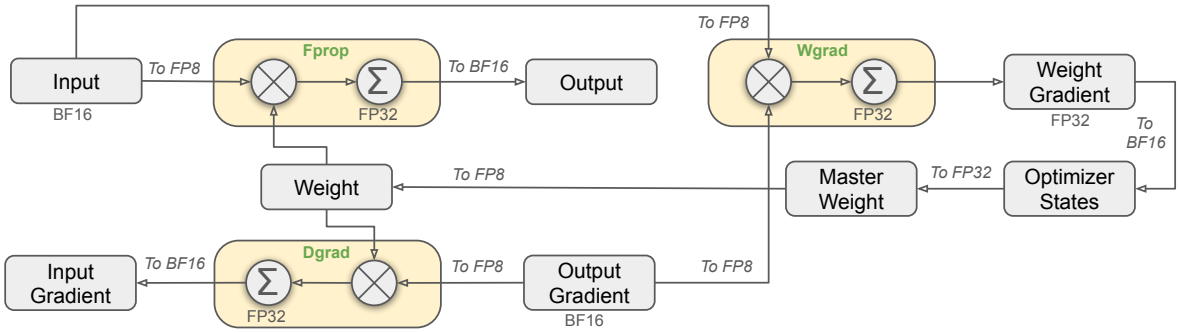

图 6: The overall mixed precision framework with FP8 data format. For clarification, only the `Linear` operator is illustrated.

对于每个令牌，当其路由决策做出后，它会首先通过 IB 传输到目标节点上具有相同节点索引的 GPU。一旦到达目标节点，我们将努力确保它能够即时通过 NVLink 转发到承载其目标专家的特定 GPU，而不被后续到达的令牌阻塞。

通过这种方式，IB 和 NVLink 的通信得以完全重叠，每个令牌可以有效地选择每个节点平均 3.2 个专家，而不会产生 NVLink 的额外开销。这意味着，尽管 DeepSeek-V3 实际上只选择 8 个路由专家，但它可以将这个数字扩展到最多 13 个专家（4 个节点 × 3.2 个专家/节点），同时保持相同的通信成本。

总体而言，在这种通信策略下，仅需 20 个 SM 就足以充分利用 IB 和 NVLink 的带宽。

具体来说，我们采用了波束专门化技术，将 20 个流处理器（SM）划分为 10 个通信通道。在调度过程中，(1) IB 发送、(2) IB 到 NVLink 的转发和 (3) NVLink 接收分别由相应的波束处理。分配给每个通信任务的波束数量根据所有 SM 的实际工作负载动态调整。

类似地，在合并过程中，(1) NVLink 发送、(2) NVLink 到 IB 的转发和累积，以及 (3) IB 接收和累积也由动态调整的波束处理。此外，调度和合并内核与计算流重叠，因此我们还考虑它们对其他 SM 计算内核的影响。具体而言，我们采用定制的 PTX（并行线程执行）指令，并自动调优通信块的大小，这显著减少了 L2 缓存的使用和对其他 SM 的干扰。

3.2.3 Extremely Memory Saving with Minimal Overhead

为了减少训练过程中的内存占用，我们采用了以下技术。

RMSNorm 和 MLA 上投影的重新计算。 我们在反向传播过程中重新计算所有 RMSNorm 操作和 MLA 上投影，从而消除持续存储其输出激活的需要。通过这种策略，虽然会有少量的开销，但显著减少了存储激活所需的内存。

CPU 中的指数移动平均。 在训练过程中，我们保留模型参数的指数移动平均（EMA），以便在学习率衰减后对模型性能进行早期估计。EMA 参数存储在 CPU 内存中，并在每个训练步骤后异步更新。这种方法使我们能够维护 EMA 参数，而不会增加额外的内存或时间开销。

多令牌预测的共享嵌入和输出头。 通过 DualPipe 策略，我们将模型的最浅层（包括嵌入层）和最深层（包括输出头）部署在同一个 PP 排位上。这种安排使得 MTP 模块和主模型之间的共享嵌入和输出头可以物理共享参数和梯度。这个物理共享机制进一步提高了我们的内存效率。

3.3 FP8 精度训练

受到最近低精度训练的进展启发，我们提出了一种细粒度混合精度框架，利用 FP8 数据格式来训练 DeepSeek-V3 模型。尽管低精度训练具有巨大潜力，但在激活值、权重和梯度中常常存在异常值，这限制了其应用。尽管在推理量化方面已取得显著进展，但关于低精度技术在大规模语言模型预训练中的成功应用的研究仍然相对较少。为了解决这个挑战并有效扩展 FP8 格式的动态范围，我们提出了一种细粒度量化策略：基于 $1 \times N_c$ 元素的切片分组或基于 $N_c \times N_c$ 元素的块分组。通过增加精度的累积过程，我们有效缓解了与解量化相关的开销，这对实现准确的 FP8 通用矩阵乘法（GEMM）至关重要。此外，为了进一步减少 MoE 训练中的内存和通信开销，我们以 FP8 格式缓存和调度激活值，同时以 BF16 格式存储低精度优化器状态。我们在与 DeepSeek-V2-Lite 和 DeepSeek-V2 类似的两个模型规模上验证了所提出的 FP8 混合精度框架，并训练了大约 1 万亿个 tokens（详细信息请参见附录 A.1）。值得注意的是，与 BF16 基准相比，我们的 FP8 训练模型的相对损失误差始终保持在 0.25% 以下，处于训练随机性的可接受范围内。

3.3.1 混合精度框架

基于广泛采用的低精度训练技术，我们提出了一种用于 FP8 训练的混合精度框架。在该框架中，大多数计算密集型操作使用 FP8 进行处理，而一些关键操作则通过策略性地保持原始数据格式，以平衡训练效率和数值稳定性。整体框架如图 6所示。

首先，为了加速模型训练，大多数核心计算内核（即 GEMM 操作）采用 FP8 精度实现。这些 GEMM 操作接受 FP8 张量作为输入，并生成 BF16 或 FP32 格式的输出。如图 6所示，与 `Linear` 操作相关的三个 GEMM 操作——`Fprop`（前向传播）、`Dgrad`（激活反向传播）和 `Wgrad`（权重反向传播）——都在 FP8 中执行。与原始的 BF16 方法相比，这种设计理论上使得计算速度翻倍。此外，FP8 的 `Wgrad` GEMM 允许激活值以 FP8 格式存储，并在反向传播中使用。这大大减少了内存消耗。

尽管 FP8 格式在效率上具有优势，但某些操作仍然由于对低精度计算的敏感性，要求更高的精度。此外，一些低成本操作也可以使用更高的精度，而对整体训练成本的影响几乎可以忽略不计。因此，在经过仔细调查后，我们决定对于以下组件保持原始精度（例如 BF16 或 FP32）：嵌入模块、输出头、MoE 门控模块、归一化操作符和注意力操作符。针对性地保留高精度可以确保 DeepSeek-V3 训练过程中的稳定性。

为了进一步确保数值稳定性，我们以更高精度存储主权重、权重梯度和优化器状态。尽管这些高精度组件会引入一些内存开销，但通过在我们的分布式训练系统中实现高效的分片，能够最小化它们的影响。

3.3.2 量化和乘法带来的精度提升

基于我们的混合精度 FP8 框架，我们引入了几种策略来提高低精度训练的准确性，重点优化量化方法和乘法过程。

细粒度量化。 在低精度训练框架中，由于 FP8 格式的动态范围有限，且其指数位数较少，溢出和下溢是常见的挑战。作为一种标准做法，输入分布通过将输入张量的最大绝对值缩放到 FP8 可表示的最大值，来对齐到 FP8 格式的表示范围。这种方法使得低精度训练对激活值的异常值非常敏感，异常值可能会严重降低量化精度。为了解决这个问题，我们提出了一种细粒度量化方法，在更细的层面上进行缩放。如图 7（a）所示，(1) 对于激活值，我们按 `1x128` 的切片方式对元素进行分组和缩放（即每个 token 每 128 个通道）；(2) 对于权重，我们按 `128x128` 的块方式对元素进行分组和缩放（即每 128 个输入通道对 128 个输出通道）。这种方法确保量化过程能够通过根据较小的元素组调整缩放来更好地适应异常值。在附

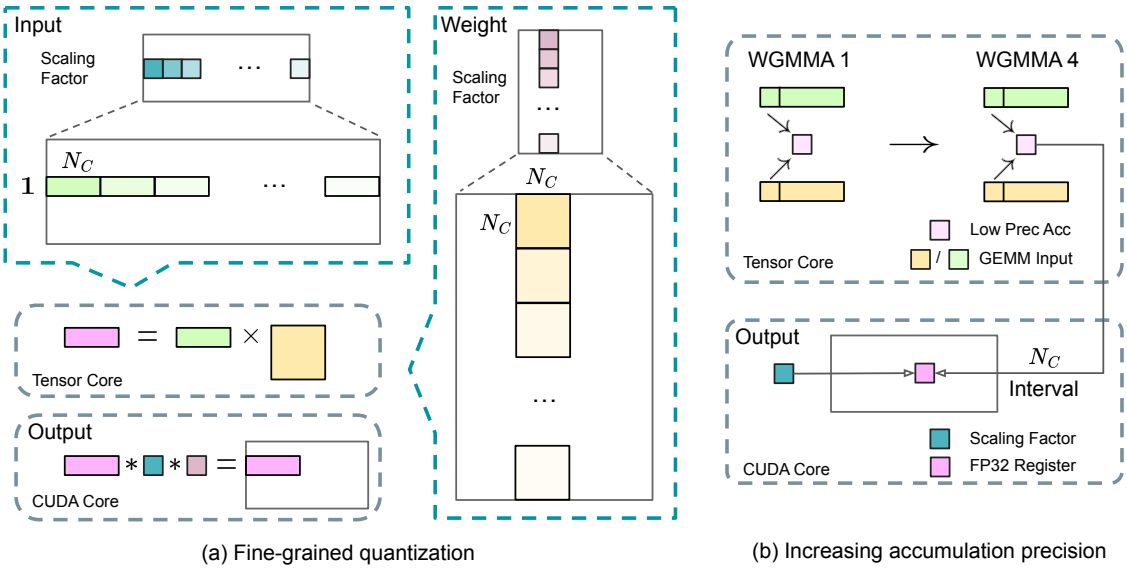

图 7: (a) We propose a fine-grained quantization method to mitigate quantization errors caused by feature outliers; for illustration simplicity, only `Fprop` is illustrated. (b) In conjunction with our quantization strategy, we improve the FP8 GEMM precision by promoting to CUDA Cores at an interval of $N_C = 128$ elements MMA for the high-precision accumulation.

录 A.2中，我们进一步讨论了当我们按与权重量化相同的方式对激活值进行块级分组和缩放时，可能出现的训练不稳定性。

我们方法中的一个关键修改是引入了沿着 GEMM 操作内部维度的每组缩放因子。这一功能在标准的 FP8 GEMM 中并不直接支持，但结合我们的精确 FP32 累积策略，可以高效地实现。

值得注意的是，我们的细粒度量化策略与微缩格式的理念高度一致，而 NVIDIA 下一代 GPU（Blackwell 系列）的 Tensor Cores 已宣布支持具有更小量化粒度的微缩格式。我们希望我们的设计能为未来的工作提供参考，以跟上最新 GPU 架构的发展。

提高累积精度。 低精度 GEMM 操作常常遭遇下溢问题，它们的精度在很大程度上依赖于高精度的累积，通常是在 FP32 精度下进行的。然而，我们观察到，在 NVIDIA H800 GPU 上，FP8 GEMM 的累积精度仅能保留大约 14 位，这明显低于 FP32 累积精度。当内部维度 `K` 较大时，这个问题会变得更加明显，这通常出现在大规模模型训练的典型场景中，其中批量大小和模型宽度增大。以 `K` = 4096 的两个随机矩阵的 GEMM 操作为例，在我们的初步测试中，Tensor Cores 中有限的累积精度导致最大相对误差接近 2%。尽管存在这些问题，有限的累积精度仍然是一些 FP8 框架中的默认选项，这严重制约了训练的准确性。

为了解决这个问题，我们采用了提升到 CUDA Cores 以获得更高精度的策略。这一过程如图 7（b）所示。具体来说，在 Tensor Cores 上执行 MMA（矩阵乘法累加）时，使用有限的位宽累积中间结果。一旦达到 N_C 的间隔，这些部分结果将被复制到 CUDA Cores 上的 FP32 寄存器中，在那里执行全精度的 FP32 累积。如前所述，我们的细粒度量化在内部维度 `K` 上应用每组缩放因子。这些缩放因子可以在 CUDA Cores 上高效地与解量化过程一起进行乘法运算，且几乎没有额外的计算开销。

值得注意的是，这一修改减少了单个 warpgroup 的 WGMMA（warp 组级别矩阵乘法累加）指令发射率。然而，在 H800 架构上，通常会有两个 WGMMA 并行存在：一个 warpgroup 执行提升操作，另一个则执行 MMA 操作。这种设计使得两个操作能够重叠执行，从而保持 Tensor Cores 的高利用率。根据我们的实验，将 $N_C = 128$ 元素（相当于 4 个 WGMMAs）设置为最小的累积间隔，可以显著提高精度，同时不会引入过多的开销。

尾数优于指数。 与先前工作采用的混合 FP8 格式不同，后者在 `Fprop` 中使用 `E4M3`（4 位指数和 3 位尾数），在 `Dgrad` 和 `Wgrad` 中使用 `E5M2`（5 位指数和 2 位尾数），我们在所有张量中都采用 `E4M3` 格式，以获得更高的精度。我们认为这种方法可行的原因在于我们的细粒度量化策略，即切片和块级别的缩放。通过对较小的元素组进行操作，我们的方法有效地在这些分组元素之间共享指数位，从而减轻了有限动态范围的影响。

在线量化。 延迟量化被应用于张量级量化框架中，该框架维护了先前迭代中最大绝对值的历史记录，以推测当前值。为了确保准确的缩放因子并简化框架，我们对每个 `1x128` 激活切片或 `128x128` 权重块在线计算最大绝对值。基于该值，我们推导出缩放因子，然后在线将激活值或权重量化为 FP8 格式。

3.3.3 低精度存储和通信

结合我们的 FP8 训练框架，我们通过将缓存的激活值和优化器状态压缩为低精度格式，进一步减少了内存消耗和通信开销。

低精度优化器状态。 我们采用 BF16 数据格式而不是 FP32 来跟踪 AdamW 优化器中的一阶和二阶矩，且没有引起明显的性能下降。然而，主权重（由优化器存储）和梯度（用于批量大小累积）仍然保留在 FP32 中，以确保整个训练过程中的数值稳定性。

低精度激活值。 如图 6所示，`Wgrad` 操作在 FP8 中执行。为了减少内存消耗，在 `Linear` 操作的反向传播中，将激活值缓存为 FP8 格式是一个自然的选择。然而，针对一些操作，我们在低成本高精度训练中进行了特别考虑：

(1) 注意力操作符后的 `Linear` 输入。这些激活值也用于注意力操作符的反向传播，因此对精度比较敏感。我们为这些激活值采用了定制的 `E5M6` 数据格式。此外，这些激活值将在反向传播中从 `1x128` 量化切片转换为 `128x1` 切片。为了避免引入额外的量化误差，所有的缩放因子都采用整数幂的 2 进行四舍五入缩放。

(2) MoE 中的 SwiGLU 操作符的输入。为了进一步降低内存开销，我们缓存 SwiGLU 操作符的输入，并在反向传播中重新计算其输出。这些激活值也使用我们的细粒度量化方法以 FP8 格式存储，在内存效率和计算精度之间取得平衡。

低精度通信。 通信带宽是 MoE 模型训练中的一个关键瓶颈。为了缓解这一挑战，我们将 MoE 上升投影前的激活值量化为 FP8，然后应用 `dispatch` 组件，这与 MoE 上升投影中的 FP8 `Fprop` 兼容。与注意力操作符后的 `Linear` 输入类似，这些激活值的缩放因子是 2 的整数幂。类似的策略也应用于 MoE 下降投影前的激活梯度。对于前向和反向的 `combine` 组件，我们将它们保留为 BF16，以确保训练管道中关键部分的训练精度。

3.4 推理和部署

3.4.1 Prefilling

3.4.2 解码

3.4.3 Communication Hardware

3.4.4 Compute Hardware

4 预训练

4.1 训练数据的构成

与 DeepSeek-V2 相比，我们通过增强数学和编程样本的比例来优化预训练语料库，同时扩展了多语言覆盖范围，超越了英语和中文。此外，我们的数据处理管道经过改进，以最小化冗余，同时保持语料库的多样性。受 Ding2024FewerTI 的启发，我们实施了文档打包方法以确保数据完整性，但在训练过程中未采用跨样本注意力掩码。最后，DeepSeek-V3 的训练语料库由 14.8T 高质量和多样化的标记组成。

在 DeepSeekCoder-V2 的训练过程中，我们观察到填充中间（Fill-in-Middle，FIM）策略并未损害下一个标记预测能力，同时使模型能够基于上下文线索准确预测中间文本。与 DeepSeekCoder-V2 一致，我们在 DeepSeek-V3 的预训练中也采用了 FIM 策略。具体来说，我们使用前缀-后缀-中间（Prefix-Suffix-Middle，PSM）框架来构建数据，如下所示：

$$\texttt{<|fim_begin|>}f_{\text{pre}}\texttt{<|fim_hole|>}f_{\text{suf}}\texttt{<|fim_end|>}f_{\text{middle}}\texttt{<|eos_token|>}.$$

该结构在文档级别应用，作为预打包过程的一部分。FIM 策略的应用比例为 0.1，符合 PSM 框架。

DeepSeek-V3 的分词器采用字节级 BPE，扩展词汇量为 128K 个标记。我们的分词器的预分词器和训练数据经过修改，以优化多语言压缩效率。此外，与 DeepSeek-V2 相比，新预分词器引入了将标点符号和换行符结合的标记。然而，当模型处理没有终止换行符的多行提示时，这种技巧可能会引入标记边界偏差，特别是在少样本评估提示中。为了解决这个问题，我们在训练过程中随机拆分一定比例的这种组合标记，从而使模型接触到更广泛的特殊情况，并减轻这种偏差。

4.2 超参数

4.3 长上下文扩展

4.4 评估

4.4.1 评估结果

4.5 讨论

4.5.1 Ablation Studies for Multi-Token Prediction

4.5.2 Ablation Studies for the Auxiliary-Loss-Free Balancing Strategy

4.5.3 Batch-Wise Load Balance VS. Sequence-Wise Load Balance

5 后训练

5.1 监督微调 (Supervised Fine-Tuning)

5.2 强化学习

5.2.1 奖励模型

5.2.2 组相对策略优化 (Group Relative Policy Optimization)

5.3 评估

5.3.1 评估设置

5.3.2 标准评估

表 3 展示了评估结果，表明 DeepSeek-V3 是表现最好的开源模型。此外，它在与前沿闭源模型如 GPT-4o 和 Claude-3.5-Sonnet 的竞争中也表现出色。

英文基准测试 MMLU 是一个广泛认可的基准，旨在评估大型语言模型在多种知识领域和任务中的表现。DeepSeek-V3 展现出具有竞争力的性能，与顶尖模型如 LLaMA-3.1-405B、GPT-4o 和 Claude-Sonnet 3.5 不相上下，同时显著超越 Qwen2.5 72B。此外，DeepSeek-V3 在 MMLU-Pro 这一更具挑战性的教育知识基准测试中表现优异，接近 Claude-Sonnet 3.5。在 MMLU-Redux（一个修正标签的 MMLU 精简版）中，DeepSeek-V3 超越了其他同类模型。此外，在 GPQA-Diamond 这一博士级评估测试平台上，DeepSeek-V3 取得了卓越的成绩，仅次于 Claude 3.5 Sonnet，且显著超越了所有其他竞争对手。

在长文本理解基准测试中，如 DROP、LongBench v2 和 FRAMES，DeepSeek-V3 继续展示其作为顶尖模型的地位。在 DROP 的 3-shot 设置中，它取得了令人印象深刻的 91.6 F1 分数，超越了该类别中的所有其他模型。在 FRAMES 这一需要在超过 10 万个标记上下文中进行问答的基准测试中，DeepSeek-V3 紧随 GPT-4o，其表现显著优于其他所有模型。这展示了 DeepSeek-V3 在处理极长文本任务方面的强大能力。

DeepSeek-V3 的长文本处理能力在 LongBench v2 上得到了进一步验证，该数据集在 DeepSeek V3 发布前几周发布。在事实知识基准测试 SimpleQA 中，DeepSeek-V3 落后于 GPT-4o 和 Claude-Sonnet，这主要是由于其设计重点和资源分配。DeepSeek-V3 将更多的训练标记分配给学习中文知识，从而在 C-SimpleQA 上表现出色。在遵循指令的基准测试中，DeepSeek-V3 显著超越了其前身 DeepSeek-V2 系列，突显了其在理解和遵循用户定义格式约束方面的改进能力。

代码与数学基准测试 编码是大型语言模型（LLMs）面临的一项具有挑战性且实用的任务，涵盖了工程相关的任务，如 SWE-Bench-Verified 和 Aider，以及算法任务，如 HumanEval 和 LiveCodeBench。在工程任务中，DeepSeek-V3 落后于 Claude-Sonnet-3.5-1022，但显著优于开源模型。开源的 DeepSeek-V3 有望促进与编码相关的工程任务的进展。通过提供其强大的能力，DeepSeek-V3 可以推动软件工程和算法开发等领域的创新与改进，使开发者和研究人员能够拓展开源模型在编码任务中的边界。

在算法任务中，DeepSeek-V3 展现出卓越的表现，超越了 HumanEval-Mul 和 LiveCodeBench 等基准测试中的所有基线。这一成功归因于其先进的知识蒸馏技术，有效提升了其在算法任务中的代码生成和问题解决能力。

在数学基准测试中，DeepSeek-V3 展现出卓越的表现，显著超越了基线，并为非 o1-like 模型设定了新的最先进水平。具体而言，在 AIME、MATH-500 和 CNMO 2024 上，DeepSeek-V3 的绝对得分比第二名模型 Qwen2.5 72B 高出约 10%，这一差距在如此具有挑战性的基准测试中是相当显著的。这一卓越能力突显了 DeepSeek-R1 中蒸馏技术的有效性，该技术已被证明对非 o1-like 模型极为有益。

中文基准测试 Qwen 和 DeepSeek 是两个在中文和英文方面具有强大支持的代表性模型系列。在事实基准测试中文 SimpleQA 中，DeepSeek-V3 超越了 Qwen2.5-72B 16.4 分，尽管 Qwen2.5 是在一个更大的语料库上训练的，包含 18T 标记，比 DeepSeek-V3 预训练的 14.8T 标记多出 20

在 C-Eval（一个代表性的中文教育知识评估基准）和 CLUEWSC（中文 Winograd 语料库挑战）中，DeepSeek-V3 和 Qwen2.5-72B 表现出相似的性能水平，表明这两个模型在应对具有挑战性的中文推理和教育任务方面都经过了良好的优化。

5.3.3 开放式评估

除了标准基准测试，我们还使用大型语言模型（LLMs）作为评判者，对开放式生成任务进行了评估，结果如表 4 所示。具体而言，我们遵循了 AlpacaEval 2.0 和 Arena-Hard 的原始配置，利用 GPT-4-Turbo-1106 进行成对比较的评判。

在 Arena-Hard 上，DeepSeek-V3 以超过 86% 的胜率击败基线模型 GPT-4-0314，其表现与顶尖模型如 Claude-Sonnet-3.5-1022 不相上下。这突显了 DeepSeek-V3 的强大能力，尤其是在处理复杂提示时，包括编码和调试任务。此外，DeepSeek-V3 成为第一个在 Arena-Hard 基准测试中超过 85% 的开源模型，这一成就显著缩小了开源模型与闭源模型之间的性能差距，为开源模型在挑战性领域的成就设定了新标准。

同样，DeepSeek-V3 在 AlpacaEval 2.0 上表现出色，超越了闭源和开源模型。这证明了它在写作任务和处理简单问答场景方面的卓越能力。值得注意的是，它以 20% 的显著优势超过了 DeepSeek-V2.5-0905，突显了在处理简单任务方面的重大改进，并展示了其进步的有效性。

5.3.4 DeepSeek-V3 作为通用的奖励模型

我们将 DeepSeek-V3 的判断能力与最先进的模型进行比较，即 GPT-4o 和 Claude-3.5。表 5 展示了这些模型在 RewardBench 中的表现。

DeepSeek-V3 的表现与最佳版本的 GPT-4o-0806 和 Claude-3.5-Sonnet-1022 相当，同时超越了其他版本。此外，DeepSeek-V3 的判断能力还可以通过投票技术得到增强。因此，我们使用 DeepSeek-V3 结合投票技术，对开放式问题提供自我反馈，从而提高对齐过程的有效性和鲁棒性。

5.4 讨论

5.4.1 从 DeepSeek-R1 蒸馏

我们基于 DeepSeek-V2.5 对来自 DeepSeek-R1 的蒸馏贡献进行了消融实验。基线模型是在短链条思维（CoT）数据上训练的，而其竞争模型则使用了上述专家检查点生成的数据。

表 6 显示了蒸馏数据的有效性，在 LiveCodeBench 和 MATH-500 基准测试中均显著提高了性能。我们的实验揭示了一个有趣的权衡：蒸馏导致了更好的性能，但也显著增加了平均响应长度。为了在模型准确性和计算效率之间保持平衡，我们为 DeepSeek-V3 在蒸馏中仔细选择了最佳设置。

我们的研究表明，从推理模型中进行知识蒸馏是后训练优化的一个有前景的方向。虽然我们目前的工作集中在数学和编码领域的数据蒸馏上，但这种方法在各种任务领域中显示出更广泛应用的潜力。在这些特定领域中展示的有效性表明，长链条思维蒸馏可能对增强其他需要复杂推理的认知任务中的模型性能具有重要价值。进一步探索这种方法在不同领域的应用仍然是未来研究的重要方向。

5.4.2 Self-Rewarding

奖励在强化学习（RL）中发挥着关键作用，引导优化过程。在一些通过外部工具验证相对简单的领域，例如某些编码或数学场景，强化学习表现出卓越的效果。然而，在更一般的场景中，通过硬编码构建反馈机制是不可行的。

在 DeepSeek-V3 的开发过程中，对于这些更广泛的背景，我们采用了宪法 AI 方法，利用 DeepSeek-V3 自身的投票评估结果作为反馈来源。这种方法产生了显著的对齐效果，显著提升了 DeepSeek-V3 在主观评估中的表现。通过整合额外的宪法输入，DeepSeek-V3 可以朝着宪法方向进行优化。

我们相信，这种将补充信息与大型语言模型（LLM）结合作为反馈来源的范式至关重要。LLM 作为一个多功能处理器，能够将来自不同场景的非结构化信息转化为奖励，最终促进 LLM 的自我改进。除了自我奖励外，我们还致力于发现其他通用且可扩展的奖励方法，以持续提升模型在一般场景中的能力。

5.4.3 Multi-Token Prediction Evaluation

DeepSeek-V3 不仅仅预测下一个单个令牌，而是通过 MTP 技术预测下两个令牌。结合推测解码的框架，可以显著加快模型的解码速度。

一个自然的问题是关于额外预测令牌的接受率。根据我们的评估，第二个令牌预测的接受率在不同生成主题中范围在 85% 到 90% 之间，显示出一致的可靠性。这个高接受率使得 DeepSeek-V3 能够实现显著提高的解码速度，达到 1.8 倍的 TPS（每秒令牌数）。

6 结论，局限性和未来的方向

在本文中，我们介绍了 DeepSeek-V3，这是一个大型 MoE 语言模型，具有 671B 的总参数和 37B 的激活参数，训练数据量达到 14.8T 令牌。除了 MLA 和 DeepSeekMoE 架构外，它还开创了一种无辅助损失的负载平衡策略，并设定了多令牌预测训练目标，以实现更强的性能。

由于支持 FP8 训练和精细的工程优化，DeepSeek-V3 的训练具有成本效益。后训练阶段成功地从 DeepSeek-R1 系列模型中提炼了推理能力。全面评估表明，DeepSeek-V3 已成为当前最强的开源模型，并且在性能上与领先的闭源模型如 GPT-4o 和 Claude-3.5-Sonnet 相媲美。

尽管性能强大，但它仍保持了经济的训练成本。完整训练（包括预训练、上下文长度扩展和后训练）仅需 2.788M H800 GPU 小时。

尽管我们认可 DeepSeek-V3 的强大性能和成本效益，但我们也认识到它存在一些局限性，尤其是在部署方面。首先，为了确保高效的推理，DeepSeek-V3 的推荐部署单元相对较大，这可能会对小型团队造

成负担。其次，尽管我们对 DeepSeek-V3 的部署策略已经实现了端到端生成速度比 DeepSeek-V2 快两倍以上，但仍存在进一步优化的潜力。幸运的是，随着更先进硬件的发展，这些局限性有望自然得到解决。

DeepSeek 始终坚持开放源代码模型的长期发展路线，旨在稳步接近 AGI（人工通用智能）的最终目标。未来，我们计划在以下方向进行战略性投资研究。

- 我们将持续研究和优化我们的模型架构，旨在进一步提高训练和推理效率，努力实现对无限上下文长度的高效支持。此外，我们还将尝试突破 Transformer 的架构限制，从而推动其建模能力的边界。
- 我们将不断迭代训练数据的数量和质量，并探索纳入额外训练信号来源，旨在推动数据在更广泛维度上的扩展。
- 我们将持续探索和迭代模型的深度思考能力，旨在通过扩展推理的长度和深度来增强模型的智能和解决问题的能力。
- 我们将探索更全面和多维度的模型评估方法，以防止在研究中倾向于优化固定的一组基准，这可能会对模型能力产生误导性的印象，并影响我们的基础评估。

Appendix

A Ablation Studies for Low-Precision Training

A.1 FP8 v.s. BF16 Training

A.2 Discussion About Block-Wise Quantization

B Expert Specialization Patterns of the 16B Aux-Loss-Based and Aux-Loss-Free Models

	Benchmark (Metric)	DeepSeek V2-0506	DeepSeek V2.5-0905	Qwen2.5 72B-Inst.	LLaMA-3.1 405B-Inst.	Claude-3.5-Sonnet-1022	GPT-4o 0513	DeepSeek V3
	Architecture	MoE	MoE	Dense	Dense	-	-	MoE
	# Activated Params	21B	21B	72B	405B	-	-	37B
	# Total Params	236B	236B	72B	405B	-	-	671B
English	MMLU (EM)	78.2	80.6	85.3	**88.6**	**88.3**	87.2	**88.5**
	MMLU-Redux (EM)	77.9	80.3	85.6	86.2	**88.9**	88.0	**89.1**
	MMLU-Pro (EM)	58.5	66.2	71.6	73.3	**78.0**	72.6	75.9
	DROP (3-shot F1)	83.0	87.8	76.7	88.7	88.3	83.7	**91.**
	IF-Eval (Prompt Strict)	57.7	80.6	84.1	86.0	**86.5**	84.3	86.1
	GPQA-Diamond (Pass@1)	35.3	41.3	49.0	51.1	**65.0**	49.9	59.1
	SimpleQA (Correct)	9.0	10.2	9.1	17.1	28.4	**38.2**	24.9
	FRAMES (Acc.)	66.9	65.4	69.8	70.0	72.5	**80.5**	73.3
	LongBench v2 (Acc.)	31.6	35.4	39.4	36.1	41.0	48.1	**48.7**
Code	HumanEval-Mul (Pass@1)	69.3	77.4	77.3	77.2	81.7	80.5	**82.6**
	LiveCodeBench (Pass@1-COT)	18.8	29.2	31.1	28.4	36.3	33.4	**40.5**
	LiveCodeBench (Pass@1)	20.3	28.4	28.7	30.1	32.8	34.2	**37.6**
	Codeforces (Percentile)	17.5	35.6	24.8	25.3	20.3	23.6	**51.6**
	SWE Verified (Resolved)	-	22.6	23.8	24.5	**50.8**	38.8	42.0
	Aider-Edit (Acc.)	60.3	71.6	65.4	63.9	**84.2**	72.9	79.7
	Aider-Polyglot (Acc.)	-	18.2	7.6	5.8	45.3	16.0	**49.6**
Math	AIME 2024 (Pass@1)	4.6	16.7	23.3	23.3	16.0	9.3	**39.2**
	MATH-500 (EM)	56.3	74.7	80.0	73.8	78.3	74.6	**90.2**
	CNMO 2024 (Pass@1)	2.8	10.8	15.9	6.8	13.1	10.8	**43.2**
Chinese	CLUEWSC (EM)	89.9	90.4	**91.4**	84.7	85.4	87.9	90.9
	C-Eval (EM)	78.6	79.5	86.1	61.5	76.7	76.0	**86.5**
	C-SimpleQA (Correct)	48.5	54.1	48.4	50.4	51.3	59.3	**64.8**

表 3: Comparison between DeepSeek-V3 and other representative chat models. All models are evaluated in a configuration that limits the output length to 8K. Benchmarks containing fewer than 1000 samples are tested multiple times using varying temperature settings to derive robust final results. DeepSeek-V3 stands as the best-performing open-source model, and also exhibits competitive performance against frontier closed-source models.

Model	Arena-Hard	AlpacaEval 2.0
DeepSeek-V2.5-0905	76.2	50.5
Qwen2.5-72B-Instruct	81.2	49.1
LLaMA-3.1 405B	69.3	40.5
GPT-4o-0513	80.4	51.1
Claude-Sonnet-3.5-1022	85.2	52.0
DeepSeek-V3	**85.5**	**70.0**

表 4: English open-ended conversation evaluations. For AlpacaEval 2.0, we use the length-controlled win rate as the metric.

Model	Chat	Chat-Hard	Safety	Reasoning	Average
GPT-4o-0513	96.6	70.4	86.7	84.9	84.7
GPT-4o-0806	96.1	76.1	88.1	86.6	86.7
GPT-4o-1120	95.8	71.3	86.2	85.2	84.6
Claude-3.5-sonnet-0620	96.4	74.0	81.6	84.7	84.2
Claude-3.5-sonnet-1022	96.4	79.7	91.1	87.6	88.7
DeepSeek-V3	96.9	79.8	87.0	84.3	87.0
DeepSeek-V3 (maj@6)	96.9	82.6	89.5	89.2	89.6

表 5: Performances of GPT-4o, Claude-3.5-sonnet and DeepSeek-V3 on RewardBench.

Model	LiveCodeBench-CoT		MATH-500	
	Pass@1	Length	Pass@1	Length
DeepSeek-V2.5 Baseline	31.1	718	74.6	769
DeepSeek-V2.5 +R1 Distill	37.4	783	83.2	1510

表 6: The contribution of distillation from DeepSeek-R1. The evaluation settings of LiveCodeBench and MATH-500 are the same as in Table 3.