DeepSeek-V3 技术报告

左元翻译

日期：February 6, 2025

摘　要

我们推出了 DeepSeek-V3，这是一个强大的混合专家（Mixture-of-Experts, MoE）语言模型，总参数量为 6710 亿，每个 token 激活的参数量为 370 亿。为了实现高效的推理和成本效益高的训练，DeepSeek-V3 采用了多头潜在注意力（Multi-head Latent Attention, MLA）和 DeepSeekMoE 架构，这些架构在 DeepSeek-V2 中得到了充分验证。此外，DeepSeek-V3 首创了一种无辅助损失的负载均衡策略，并设定了多 token 预测的训练目标，以实现更强的性能。我们在 14.8 万亿个多样且高质量的 token 上对 DeepSeek-V3 进行了预训练，随后通过监督微调（Supervised Fine-Tuning）和强化学习（Reinforcement Learning）阶段充分挖掘其潜力。综合评估表明，DeepSeek-V3 的表现优于其他开源模型，并与领先的闭源模型性能相当。尽管性能卓越，DeepSeek-V3 的完整训练仅需 278.8 万 H800 GPU 小时。此外，其训练过程非常稳定。在整个训练过程中，我们没有遇到任何不可恢复的损失突增或执行任何回滚操作。模型检查点可在https://github.com/deepseek-ai/DeepSeek-V3获取。

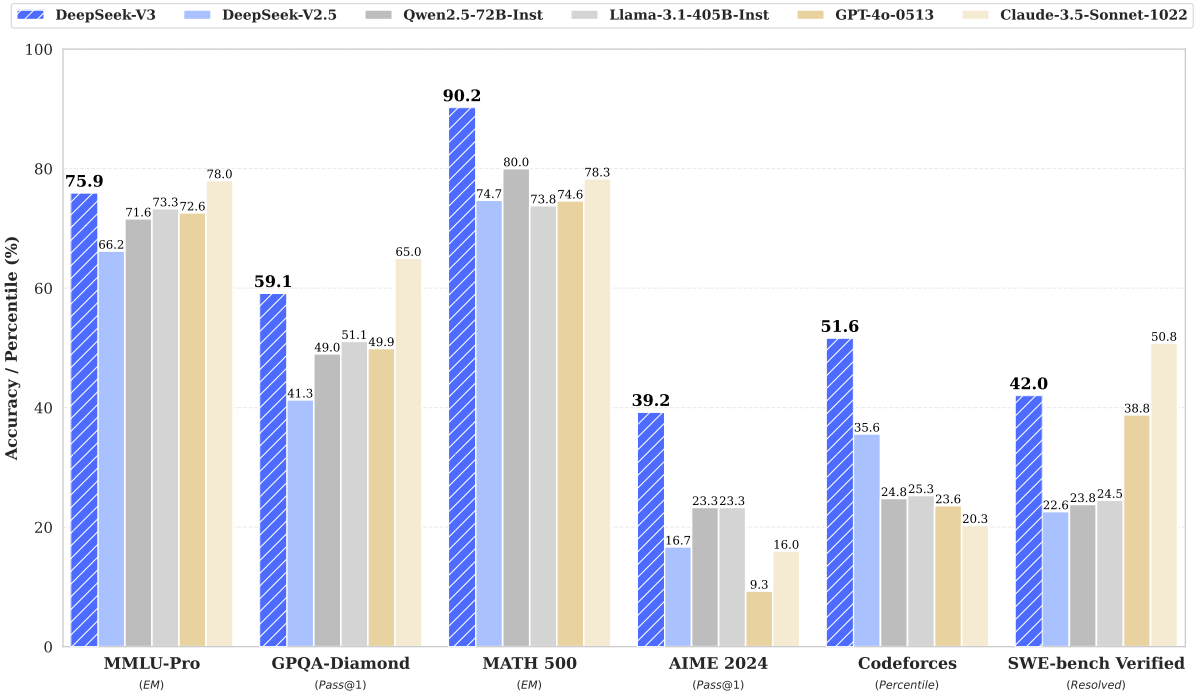

图 1: DeepSeek-V3 和竞品在性能基准测试中的比较。

目录

1 简介 **3**

2 架构 **6**

2.1 基本架构 6

2.1.1 多头潜在注意力 (Multi-Head Latent Attention) 6

2.1.2 DeepSeekMoE with Auxiliary-Loss-Free Load Balancing 6

2.2 多 Token 预测 (Multi-Token Prediction) 6

3 Infrastructures **6**

3.1 计算集群 6

3.2 训练框架 6

3.2.1 DualPipe and Computation-Communication Overlap 6

3.2.2 Efficient Implementation of Cross-Node All-to-All Communication 6

3.2.3 Extremely Memory Saving with Minimal Overhead 6

3.3 FP8 精度训练 6

3.4 推理和部署 6

3.4.1 Prefilling 6

3.4.2 解码 6

3.4.3 Communication Hardware 6

3.4.4 Compute Hardware 6

4 预训练 **6**

4.1 Data Construction 6

4.2 超参数 6

4.3 长上下文扩展 6

4.4 评估 6

4.4.1 评估结果 6

4.5 讨论 6

4.5.1 Ablation Studies for Multi-Token Prediction 6

4.5.2 Ablation Studies for the Auxiliary-Loss-Free Balancing Strategy 6

4.5.3 Batch-Wise Load Balance VS. Sequence-Wise Load Balance 6

5 后训练 **6**

5.1 监督微调 (Supervised Fine-Tuning) 6

5.2 强化学习 6

5.2.1 奖励模型 6

5.2.2 组相对策略优化 (Group Relative Policy Optimization) 6

5.3 评估 6

5.3.1 评估设置 6

5.3.2 标准评估 6

5.3.3 Open-Ended Evaluation 6

5.3.4 DeepSeek-V3 as a Generative Reward Model 6

5.4 讨论 6

5.4.1 从 DeepSeek-R1 蒸馏 6
5.4.2 Self-Rewarding 6
5.4.3 Multi-Token Prediction Evaluation 6

6 结论，局限性和未来的方向 6

Training Costs	Pre-Training	Context Extension	Post-Training	Total
in H800 GPU Hours	2664K	119K	5K	2788K
in USD	$5.328M	$0.238M	$0.01M	$5.576M

表 1: DeepSeek-V3 的训练花费，假设 H800 每个 GPU 小时的租赁费用是 $2。

1 简介

近年来，大语言模型（Large Language Models, LLMs）正在经历快速的迭代和演进，逐步缩小与通用人工智能（Artificial General Intelligence, AGI）的差距。除了闭源模型外，开源模型，包括 DeepSeek 系列、LLaMA 系列、Qwen 系列和 Mistral 系列，也在取得显著进展，努力缩小与闭源模型的差距。为了进一步突破开源模型的能力边界，我们扩大了模型规模，并推出了 DeepSeek-V3，这是一个拥有 6710 亿参数的大型混合专家（Mixture-of-Experts, MoE）模型，其中每个 token 激活的参数量为 370 亿。

以前瞻性的视角，我们始终致力于实现强大的模型性能和经济的成本。因此，在架构方面，DeepSeek-V3 仍然采用多头潜在注意力（MLA）以实现高效推理，以及 DeepSeekMoE 以实现成本效益高的训练。这两种架构在 DeepSeek-V2 中得到了验证，证明了它们在保持强大模型性能的同时实现高效训练和推理的能力。除了基础架构外，我们还实施了两项额外策略以进一步增强模型能力。首先，DeepSeek-V3 首创了一种无辅助损失的负载均衡策略，旨在最小化因鼓励负载均衡而对模型性能产生的负面影响。其次，DeepSeek-V3 采用了多 token 预测的训练目标，我们观察到这可以提升评估基准上的整体性能。

为了实现高效的训练，我们支持 FP8 混合精度训练，并对训练框架进行了全面优化。低精度训练已成为高效训练的一种有前景的解决方案，其发展与硬件能力的进步密切相关。在这项工作中，我们引入了 FP8 混合精度训练框架，并首次在超大规模模型上验证了其有效性。通过支持 FP8 计算和存储，我们实现了训练加速和 GPU 内存使用量的减少。在训练框架方面，我们设计了 DualPipe 算法以实现高效的流水线并行，该算法减少了流水线气泡，并通过计算-通信重叠隐藏了训练过程中的大部分通信。这种重叠确保了随着模型的进一步扩展，只要我们保持恒定的计算与通信比率，我们仍然可以在节点间使用细粒度的专家，同时实现近乎零的全对全通信开销。此外，我们还开发了高效的跨节点全对全通信内核，以充分利用 InfiniBand（IB）和 NVLink 的带宽。此外，我们精心优化了内存占用，使得在不使用昂贵的张量并行的情况下训练 DeepSeek-V3 成为可能。结合这些努力，我们实现了高效的训练。

在预训练阶段，我们在 14.8 万亿个高质量且多样化的 token 上训练了 DeepSeek-V3。预训练过程非常稳定。在整个训练过程中，我们没有遇到任何不可恢复的损失突增，也没有进行任何回滚操作。接下来，我们对 DeepSeek-V3 进行了两阶段的上下文长度扩展。在第一阶段，最大上下文长度扩展到 32K，在第二阶段进一步扩展到 128K。随后，我们对 DeepSeek-V3 的基础模型进行了后训练，包括监督微调（Supervised Fine-Tuning, SFT）和强化学习（Reinforcement Learning, RL），以使其与人类偏好对齐并进一步释放其潜力。在后训练阶段，我们从 DeepSeek-R1 系列模型中蒸馏了推理能力，同时精心平衡了模型准确性和生成长度之间的关系。

我们在广泛的基准测试上对 DeepSeek-V3 进行了评估。尽管训练成本经济，综合评估表明，DeepSeek-V3-Base 已成为当前最强的开源基础模型，尤其是在代码和数学领域。其聊天版本也在标准基准和开放式基准测试中优于其他开源模型，并与领先的闭源模型（包括 GPT-4o 和 Claude-3.5-Sonnet）性能相当。

最后，我们再次强调 DeepSeek-V3 的经济训练成本，总结在表 1中，这是通过我们对算法、框架和硬件的优化协同设计实现的。在预训练阶段，每万亿 token 的训练仅需 18 万 H800 GPU 小时，即在我们拥有 2048 个 H800 GPU 的集群上仅需 3.7 天。因此，我们的预训练阶段在不到两个月内完成，并消耗了 266.4 万 GPU 小时。结合上下文长度扩展所需的 11.9 万 GPU 小时和后训练的 0.5 万 GPU 小时，DeepSeek-V3 的完整训练仅需 278.8 万 GPU 小时。假设 H800 GPU 的租赁价格为每小时 2 美元，我们的总训练成本仅为 557.6 万美元。需要注意的是，上述成本仅包括 DeepSeek-V3 的官方训练，不包括在架构、算法或数据

上的前期研究和消融实验相关成本。

我们主要的贡献包括：

架构：创新的负载均衡策略和训练目标

- 在 DeepSeek-V2 的高效架构基础上，我们首创了一种无辅助损失的负载均衡策略，最大限度地减少了因鼓励负载均衡而导致的性能下降。
- 我们研究了多 token 预测（Multi-Token Prediction, MTP）目标，并证明其对模型性能有益。它还可以用于推测解码（speculative decoding）以实现推理加速。

预训练：通往终极的训练效率

- 我们设计了一个 FP8 混合精度训练框架，并首次在超大规模模型上验证了 FP8 训练的可行性和有效性。
- 通过算法、框架和硬件的协同设计，我们克服了跨节点 MoE 训练中的通信瓶颈，实现了近乎完全的计算-通信重叠。这显著提高了我们的训练效率并降低了训练成本，使我们能够在不增加额外开销的情况下进一步扩大模型规模。
- 仅以 266.4 万 H800 GPU 小时的经济成本，我们完成了 DeepSeek-V3 在 14.8 万亿 token 上的预训练，生成了当前最强的开源基础模型。预训练后的后续训练阶段仅需 10 万 GPU 小时。

后训练：从 DeepSeek-R1 进行知识蒸馏

- 我们引入了一种创新方法，将长思维链（Chain-of-Thought, CoT）模型（特别是 DeepSeek R1 系列模型之一）的推理能力蒸馏到标准 LLM（尤其是 DeepSeek-V3）中。我们的管道巧妙地将 R1 的验证和反思模式融入 DeepSeek-V3，显著提升了其推理性能。同时，我们还控制了 DeepSeek-V3 的输出风格和长度。

核心评估结果总结

- **知识**: (1) 在教育类基准测试（如 MMLU、MMLU-Pro 和 GPQA）上，DeepSeek-V3 优于所有其他开源模型，在 MMLU 上得分为 88.5，在 MMLU-Pro 上得分为 75.9，在 GPQA 上得分为 59.1。其性能与领先的闭源模型（如 GPT-4o 和 Claude-Sonnet-3.5）相当，缩小了开源与闭源模型在该领域的差距。(2) 在事实性基准测试中，DeepSeek-V3 在 SimpleQA 和中文 SimpleQA 上均表现出优于其他开源模型的性能。尽管在英文事实知识（SimpleQA）上略逊于 GPT-4o 和 Claude-Sonnet-3.5，但在中文事实知识（中文 SimpleQA）上超越了这些模型，凸显了其在中文事实知识方面的优势。
- **代码、数学和推理**: (1) DeepSeek-V3 在所有非长链思维（CoT）的开源和闭源模型中，在数学相关基准测试上实现了最先进的性能。值得注意的是，它在特定基准测试（如 MATH-500）上甚至优于 o1-preview，展示了其强大的数学推理能力。(2) 在编码相关任务中，DeepSeek-V3 成为编码竞赛基准测试（如 LiveCodeBench）中表现最佳的模型，巩固了其在该领域的领先地位。在工程相关任务中，尽管 DeepSeek-V3 的表现略低于 Claude-Sonnet-3.5，但它仍然显著领先于所有其他模型，展示了其在多样化技术基准测试中的竞争力。

在本文的剩余部分，我们首先详细阐述了 DeepSeek-V3 的模型架构（第2节）。随后，我们介绍了我们的基础设施，包括计算集群、训练框架、对 FP8 训练的支持、推理部署策略以及对未来硬件设计的建议。接下来，我们描述了预训练过程，包括训练数据的构建、超参数设置、长上下文扩展技术、相关评估以及一些讨论（第4节）。之后，我们讨论了后训练的工作，包括监督微调（SFT）、强化学习（RL）、相应的评估和讨论（第5节）。最后，我们总结了这项工作，讨论了 DeepSeek-V3 的现有局限性，并提出了未来研究的潜在方向（第6节）。

2 架构

2.1 基本架构

2.1.1 多头潜在注意力 (Multi-Head Latent Attention)

2.1.2 DeepSeekMoE with Auxiliary-Loss-Free Load Balancing

2.2 多 Token 预测 (Multi-Token Prediction)

3 Infrastructures

3.1 计算集群

3.2 训练框架

3.2.1 DualPipe and Computation-Communication Overlap

3.2.2 Efficient Implementation of Cross-Node All-to-All Communication

3.2.3 Extremely Memory Saving with Minimal Overhead

3.3 FP8 精度训练

3.4 推理和部署

3.4.1 Prefilling

3.4.2 解码

3.4.3 Communication Hardware

3.4.4 Compute Hardware

4 预训练

4.1 Data Construction

4.2 超参数

4.3 长上下文扩展

4.4 评估

4.4.1 评估结果

4.5 讨论

4.5.1 Ablation Studies for Multi-Token Prediction

4.5.2 Ablation Studies for the Auxiliary-Loss-Free Balancing Strategy

4.5.3 Batch-Wise Load Balance VS. Sequence-Wise Load Balance

5 后训练

5.1 监督微调 (Supervised Fine-Tuning)

5.2 强化学习

5.2.1 奖励模型